

# Qwen3技术报告

## 摘要

在这项工作中，我们推出了 Qwen3，这是 Qwen 模型家族的最新版本。Qwen3 包含一系列大语言模型（LLMs），旨在提升性能、效率和多语言能力。该系列模型涵盖了密集型（dense）和混合专家（Mixture-of-Expert, MoE）架构，参数规模从 0.6 亿到 2350 亿不等。Qwen3 的一项关键创新是将“思考模式”（用于复杂的多步骤推理）和“非思考模式”（用于快速的上下文驱动响应）集成到了一个统一的框架中。这消除了在不同模型之间切换的需要——例如在面向对话的模型（如 GPT-4o）和专门的推理模型（如 QwQ-32B）之间切换——并能根据用户查询或对话模板动态切换模式。同时，Qwen3 引入了“思考预算”机制，允许用户在推理过程中自适应地分配计算资源，从而根据任务的复杂性在延迟和性能之间取得平衡。此外，通过利用旗舰模型的知识，我们显著降低了构建小规模模型所需的计算资源，同时确保了它们具有很强的竞争力。实证评估表明，Qwen3 在包括代码生成、数学推理、智能体（agent）任务等多种基准测试中均取得了最先进的结果，其表现可与更大规模的 MoE 模型和专有模型相媲美。与前代版本 Qwen2.5 相比，Qwen3 将多语言支持从 29 种扩展到了 119 种语言和方言，并通过改进跨语言理解和生成能力，增强了全球用户的可访问性。为了促进可复现性以及社区驱动的研究和开发，所有 Qwen3 模型均依据 Apache 2.0 协议公开提供。

## 1 引言

人类长期以来一直致力于追求通用人工智能（AGI）或超级人工智能（ASI）。近期，诸如 GPT-4o (OpenAI, 2024)、Claude 3.7 (Anthropic, 2025)、Gemini 2.5 (DeepMind, 2025)、DeepSeek-V3 (Liu 等, 2024a)、Llama-4 (Meta-AI, 2025) 以及 Qwen2.5 (Yang 等, 2024b) 等大基础模型的进展，标志着我们在这一目标上取得了显著的进步。这些模型在跨越不同领域和任务的数万亿 token 的海量数据集上进行训练，有效地将人类的知识和能力提炼并融入其参数之中。此外，近期通过强化学习优化的推理模型的发展，凸显了基础模型在提升推理时扩展能力方面的潜力，使其能够达到更高水平的智能，例如 o3 (OpenAI, 2025) 和 DeepSeek-R1 (Guo 等, 2025)。尽管目前大多数顶尖模型仍为专有模型，但开源社区的飞速发展已大幅缩小了开源权重模型与闭源模型之间的性能差距。值得注意的是，越来越多的顶尖模型（Meta-AI, 2025; Liu 等, 2024a; Guo 等, 2025; Yang 等, 2024b）现在正以开源形式发布，这促进了人工智能领域更广泛的研究与创新。

在这项工作中，我们推出了 Qwen3，这是 Qwen 基础模型家族的最新系列。Qwen3 是一系列开源权重的大语言模型（LLMs），在各种任务和领域中均实现了最先进的性能。我们发布了包含密集型（dense）和混合专家（Mixture-of-Experts, MoE）架构的模型，参数规模从 0.6 亿到 2350 亿不等，以满足不同下游应用的需求。值得注意的是，旗舰模型 Qwen3-235B-A22B 是一款 MoE 模型，总参

数量为 2350 亿，但每个 token 仅激活 22 亿个参数。这种设计既保证了高性能，又确保了推理的高效性。

Qwen3 引入了多项关键创新，以增强其功能性和可用性。首先，它将两种不同的运行模式——“思考模式”和“非思考模式”——集成到了一个单一模型中。这使得用户无需在不同模型之间切换（例如从 Qwen2.5 切换到 QwQ），即可在两种模式间自由切换。这种灵活性确保了开发者和用户能够高效地调整模型行为，以适应特定任务。此外，Qwen3 引入了“思考预算”机制，使用户能够精细控制模型在执行任务时所投入的推理努力程度。这一能力对于优化计算资源和性能至关重要，它能让模型的“思考”行为根据现实应用中任务的复杂性变化进行调整。同时，Qwen3 在涵盖多达 119 种语言和方言的 36 万亿 token 数据上进行了预训练，有效增强了其多语言能力。这种更广泛的语言支持，放大了其在全球用例和国际应用中的部署潜力。上述进步共同确立了 Qwen3 作为一套前沿的开源大语言模型家族的地位，使其能够有效应对跨领域、跨语言的各种复杂任务。

Qwen3 的预训练过程利用了一个由约 36 万亿 token 组成的大规模数据集，这些数据经过精心策划，以确保语言和领域的多样性。为了高效地扩展训练数据，我们采用了一种多模态方法：对 Qwen2.5-VL 进行微调，使其能够从海量 PDF 文档中提取文本。我们还利用特定领域的模型生成合成数据：使用 Qwen2.5-Math 生成数学内容，使用 Qwen2.5-Coder 生成代码相关数据。预训练过程遵循三阶段策略：第一阶段：模型在约 30 万亿 token 上进行训练，以建立坚实的基础通用知识。第二阶段：模型进一步在知识密集型数据上进行训练，以增强其在科学、技术、工程和数学（STEM）以及编程等领域的推理能力。第三阶段：模型在长上下文数据上进行训练，将其最大上下文长度从 4,096 个 token 增加到 32,768 个 token。

为了使基础模型更好地契合人类偏好及下游应用场景，我们采用了一种多阶段的后训练方法，旨在同时赋能“思考”（推理）与“非思考”两种模式。在前两个阶段，我们专注于通过长思维链（Chain-of-Thought, CoT）冷启动微调以及针对数学和编程任务的强化学习，来培养模型强大的推理能力。在最后两个阶段，我们将包含推理路径与不包含推理路径的数据融合为一个统一的数据集进行进一步微调，使模型能够有效处理两种类型的输入；随后，我们应用通用领域的强化学习，以提升模型在广泛下游任务中的表现。对于较小规模的模型，我们采用了“强教弱”的蒸馏技术，利用来自更大模型的离策略和在线策略知识迁移来增强其能力。事实证明，这种来自先进“教师”模型的知识蒸馏在性能和训练效率上均显著优于强化学习。

我们在涵盖多种任务和领域的综合性基准测试集上，对模型的预训练版本和后训练版本均进行了评估。实验结果表明，我们的基础预训练模型取得了最先进的性能。经过后训练的模型，无论是在“思考模式”还是“非思考模式”下，其表现均可与领先的专有模型以及大型混合专家（MoE）模型（如 o1、o3-mini 和 DeepSeek-V3）相媲美。值得注意的是，我们的模型在代码生成、数学运算和智能体（agent）相关任务中表现尤为出色。例如，旗舰模型 Qwen3-235B-A22B 在 AIME’24 上取得了 85.7 分，在 AIME’25 (AIME, 2025) 上取得了 81.5 分，在 LiveCodeBench v5 (Jain 等, 2024) 上取得了 70.7 分，在 CodeForces 上取得了 2,056 分，以及在 BFCL v3 (Yan 等, 2024) 上取得了 70.8 分。此外，

Qwen3 系列中的其他模型也展现了与其规模相匹配的强劲性能。此外，我们观察到，增加“思考模式”下的 token 预算，能够持续提升模型在各种任务上的表现。

在接下来的章节中，我们将介绍模型架构的设计，详细介绍其训练流程，并展示预训练和后训练模型的实验结果。最后，我们将通过总结关键发现并概述未来研究的潜在方向，来结束本技术报告。

## 2 架构

Qwen3 系列包含 6 款密集型模型，即 Qwen3-0.6B、Qwen3-1.7B、Qwen3-4B、Qwen3-8B、Qwen3-14B 和 Qwen3-32B，以及 2 款 MoE 模型，即 Qwen3-30B-A3B 和 Qwen3-235B-A22B。其中旗舰模型 Qwen3-235B-A22B 总共拥有 2350 亿参数，激活参数为 220 亿。下文将详细阐述 Qwen3 模型的架构。

Qwen3 密集型模型的架构与 Qwen2.5 相似，同样采用了分组查询注意力（GQA）、SwiGLU 激活函数、旋转位置嵌入（RoPE）以及带有预归一化的 RMSNorm。除此之外，我们移除了 Qwen2 中使用的 QKV 偏置，并在注意力机制中引入了 QK-Norm，以确保 Qwen3 的训练稳定性。表 1 中提供了有关模型架构的关键信息。

Qwen3 的 MoE 模型与 Qwen3 的密集型模型共享相同的基础架构。有关模型架构的关键信息见表 2。我们沿用了 Qwen2.5-MoE 的设计，并实现了细粒度专家分段。Qwen3 MoE 模型总共拥有 128 个专家，每个 token 激活其中的 8 个专家。与 Qwen2.5-MoE 不同的是，Qwen3-MoE 的设计中取消了共享专家。此外，我们采用了全局批次负载均衡损失来鼓励专家的专业化。这些架构和训练上的创新，使得模型在下游任务中的表现得到了显著提升。

Qwen3 模型采用了 Qwen 的分词器，该分词器实现了基于字节级别的字节对编码，词汇表大小为 151,669。

Table 1: Model architecture of Qwen3 dense models.

| Models     | Layers | Heads (Q / KV) | Tie Embedding | Context Length |
|------------|--------|----------------|---------------|----------------|
| Qwen3-0.6B | 28     | 16 / 8         | Yes           | 32K            |
| Qwen3-1.7B | 28     | 16 / 8         | Yes           | 32K            |
| Qwen3-4B   | 36     | 32 / 8         | Yes           | 128K           |
| Qwen3-8B   | 36     | 32 / 8         | No            | 128K           |
| Qwen3-14B  | 40     | 40 / 8         | No            | 128K           |
| Qwen3-32B  | 64     | 64 / 8         | No            | 128K           |

Table 2: Model architecture of Qwen3 MoE models.

| Models          | Layers | Heads (Q / KV) | # Experts (Total / Activated) | Context Length |
|-----------------|--------|----------------|-------------------------------|----------------|
| Qwen3-30B-A3B   | 48     | 32 / 4         | 128 / 8                       | 128K           |
| Qwen3-235B-A22B | 94     | 64 / 4         | 128 / 8                       | 128K           |

## 3 预训练

在本节中，我们将介绍预训练数据的构建、预训练方法的详细信息，并展示基础模型在标准基准测试上的评估实验结果。

### 3.1 预训练数据

与 Qwen2.5 相比，我们大幅扩展了训练数据的规模和多样性。具体而言，我们收集的预训练 token 数量是之前的两倍，覆盖的语言数量是之前的三倍。所有 Qwen3 模型均在一个庞大且多样的数据集上进行训练，该数据集涵盖了 119 种语言和方言，总计包含 36 万亿个 token。该数据集包含了来自各个领域的高质量内容，例如编程、STEM（科学、技术、工程和数学）、推理任务、书籍、多语言文本以及合成数据。

为了进一步扩充预训练语料库，我们首先利用 Qwen2.5-VL 模型对海量类似 PDF 的文档执行文本识别。随后，利用 Qwen2.5 模型对识别出的文本进行精炼，以提升其质量。通过这一两步流程，我们成功获得了总计数万亿的高质量文本 token。此外，我们还利用 Qwen2.5、Qwen2.5-Math 和 Qwen2.5-Coder 模型合成了数万亿不同格式的文本 token，包括教科书、问答对、指令以及代码片段，覆盖了数十个领域。最后，我们通过整合额外的多语言数据并引入更多语言，进一步扩充了预训练语料库。与 Qwen2.5 使用的预训练数据相比，支持的语言数量已从 29 种显著增加至 119 种，从而增强了模型的语言覆盖范围和跨语言能力。

我们开发了一套多语言数据标注系统，旨在提升训练数据的质量和多样性。该系统已应用于我们的大规模预训练数据集，对涵盖教育价值、学科领域、专业领域及安全性等多个维度的超过 30 万亿个 token 进行了标注。这些详细的标注信息支持更高效的数据筛选与组合。与以往研究（在数据源或领域层级优化数据配比）不同，我们的方法利用小型代理模型，结合细粒度的数据标签进行了大量消融实验，从而在实例层级（instance-level）优化数据配比。

### 3.2 预训练阶段

Qwen3 模型通过三个阶段进行预训练：

（1）通用阶段 (S1)：在第一阶段预训练中，所有 Qwen3 模型均使用 4,096 个 token 的序列长度，在超过 30 万亿个 token 上进行训练。在此阶段，模型已充分学习了语言能力及通用的世界知识，训练数据涵盖了 119 种语言和方言。

（2）推理阶段 (S2)：为了进一步提升推理能力，我们通过增加 STEM（科学、技术、工程和数学）、编程、推理及合成数据的比例，来优化本阶段的预训练语料库。模型使用约 5 万亿高质量 token，在 4,096 的序列长度上进行进一步预训练。同时，我们在本阶段加快了学习率的衰减。

（3）长上下文阶段：在最终的预训练阶段，我们收集了高质量的长上下文语料库，以扩展 Qwen3 模型的上下文长度。所有模型均在数百亿个 token 上进行预训练，序列长度达到 32,768。长上下文语料库包含 75% 长度在 16,384 至 32,768 个 token 之间的文本，以及 25% 长度在 4,096 至 16,384 个 token 之间的文本。继承 Qwen2.5 的做法，我们使用 ABF 技术将 RoPE 的基础频率从 10,000 提升至 1,000,000。同时，我们引入了 YARN 和 Dual Chunk Attention (DCA) 技术，使模型在推理时的序列长度容量实现了四倍的增长。

与 Qwen2.5 类似，我们基于上述三个预训练阶段，开发了用于预测最优超参数（例如学习率调度器和批量大小）的缩放定律。通过大量实验，我们系统地研究了模型架构、训练数据、训练阶段与最



优训练超参数之间的关系。最终，我们为每个密集型或 MoE 模型设定了预测的最优学习率和批量大小策略。

### 3.3 预训练评估

我们对 Qwen3 系列的基础语言模型进行了全面评估。基础模型的评估主要侧重于其在通用知识、推理、数学、科学知识、编程以及多语言能力方面的表现。预训练基础模型的评估数据集包含了 15 个基准测试：

- 通用任务：MMLU (5-shot)、MMLU-Pro (5-shot, CoT)、MMLU-redux (5-shot)、BBH (3-shot, CoT)、SuperGPQA (5-shot, CoT)。
- 数学与 STEM 任务：GPQA (5-shot, CoT)、GSM8K (4-shot, CoT)、MATH (4-shot, CoT)。
- 编程任务：EvalPlus (0-shot) (包含 HumanEval、MBPP、HumanEval+、MBPP+ 的平均值) , MultiPL-E (0-shot) (涵盖 Python, C++, JAVA, PHP, TypeScript, C#, Bash, JavaScript) , MBPP-3shot , CRUXEval 中的 CRUX-O (1-shot)。
- 多语言任务：MGSM (8-shot, CoT) , MMMLU (5-shot) , INCLUDE (5-shot)。

在基础模型的基准测试中，我们在参数规模层面将 Qwen3 系列基础模型与 Qwen2.5 基础模型以及其他领先的开源基础模型进行了对比，这些模型包括 DeepSeek-V3 Base、Gemma-3、Llama-3 系列基础模型以及 Llama-4。所有模型均使用相同的评估流程和广泛采用的评估设置进行评测，以确保比较的公平性。

#### 评估结果总结

基于整体评估结果，我们总结了 Qwen3 基础模型的一些关键结论：

(1) 性能超越：与之前开源的 SOTA (当前最优) 密集型和 MoE 基础模型 (如 DeepSeek-V3 Base、Llama-4-Maverick Base 和 Qwen2.5-72B-Base) 相比，Qwen3-235B-A22B-Base 在大多数任务中表现更优，且其总参数量或激活参数量显著更少。

(2) MoE 模型优势：对于 Qwen3 MoE 基础模型，实验结果表明：(a) 在使用相同预训练数据的情况下，Qwen3 MoE 基础模型仅需 1/5 的激活参数量，即可达到与 Qwen3 密集型基础模型相似的性能。(b) 得益于 Qwen3 MoE 架构的改进、预训练 Token 规模的扩大以及更先进的训练策略，Qwen3 MoE 基础模型仅需不到 1/2 的激活参数量和更少的总参数量，即可超越 Qwen2.5 MoE 基础模型。(c) 即便激活参数量仅为 Qwen2.5 密集型基础模型的 1/10，Qwen3 MoE 基础模型也能达到相当的性能，这为我们带来了推理和训练成本上的显著优势。

(3) 密集型模型缩放：Qwen3 密集型基础模型的整体性能可与更高参数规模的 Qwen2.5 基础模型相媲美。例如，Qwen3-1.7B/4B/8B/14B/32B-Base 分别达到了与 Qwen2.5-3B/7B/14B/32B/72B-Base 相当的性能。特别是在 STEM、编程和推理基准测试中，Qwen3 密集型基础模型的性能甚至超越了更高参数规模的 Qwen2.5 基础模型。

详细结果如下。

我们将 Qwen3-235B-A22B-Base 与之前发布的同级别 MoE 模型 Qwen2.5-Plus-Base，以及其他领先的开源基础模型（包括 Llama-4-Maverick、Qwen2.5-72B-Base 和 DeepSeek-V3 Base）进行了对比。从表 3 的结果来看，Qwen3-235B-A22B-Base 在绝大多数评估基准上均取得了最高的性能分数。为了进行详细分析，我们进一步将该模型与其他基线模型进行了单独对比：

- (1) 与最近开源的、参数量约为其两倍的 Llama-4-Maverick-Base 模型相比，Qwen3-235B-A22B-Base 在大多数基准测试中表现依然更优。
- (2) 与之前业界领先的开源模型 DeepSeek-V3-Base 相比，Qwen3-235B-A22B-Base 在 15 个评估基准中的 14 个上均超越了前者，且总参数量仅为后者的约 1/3，激活参数量仅为后者的 2/3，这充分展示了我们模型的强大性能和成本效益。
- (3) 与我们之前发布的同级别 MoE 模型 Qwen2.5-Plus 相比，Qwen3-235B-A22B-Base 在参数量和激活参数量均更少的情况下实现了显著的性能提升，这证明了 Qwen3 在预训练数据、训练策略及模型架构方面的显著优势。
- (4) 与我们之前发布的旗舰级开源密集型模型 Qwen2.5-72B-Base 相比，Qwen3-235B-A22B-Base 在所有基准测试中均超越了后者，且激活参数量不足后者的 1/3。同时，得益于模型架构的优势，Qwen3-235B-A22B-Base 在每万亿 token 上的推理成本和训练成本均远低于 Qwen2.5-72B-Base。

## Qwen3-32B-Base

Qwen3-32B-Base 是 Qwen3 系列中最大的密集型模型。我们将它与同规模的基线模型进行了比较，包括 Gemma-3-27B 和 Qwen2.5-32B。此外，我们还引入了两个强大的基线模型：最近开源的 MoE 模型 Llama-4-Scout，其参数量是 Qwen3-32B-Base 的三倍，但激活参数量仅为后者的二分之一；以及我们之前发布的旗舰级开源密集型模型 **Qwen2.5-72B-Base**，后者的参数量是 Qwen3-32B-Base 的两倍多。结果如表 4 所示，支持以下三个关键结论：

- (1) 对比同规模模型：Qwen3-32B-Base 在大多数基准测试中优于 Qwen2.5-32B-Base 和 Gemma-3-27B Base。值得注意的是，Qwen3-32B-Base 在 MMLU-Pro 上取得了 65.54 分，在 SuperGPQA 上取得了 39.78 分，显著超越了其前身 Qwen2.5-32B-Base。此外，Qwen3-32B-Base 在编码基准测试上的得分也显著高于所有基线模型。
- (2) 对比更大规模的模型：令人惊讶的是，我们发现 Qwen3-32B-Base 与 Qwen2.5-72B-Base 相比表现出了很强的竞争力。尽管 Qwen3-32B-Base 的参数量不足 Qwen2.5-72B-Base 的一半，但在 15 个评估基准中的 10 个上均超越了后者。在编程、数学和推理基准测试中，Qwen3-32B-Base 优势尤为突出。
- (3) 对比 MoE 模型：与 Llama-4-Scout-Base 相比，Qwen3-32B-Base 在全部 15 个基准测试中均显著优于后者。Qwen3-32B-Base 的参数量仅为 Llama-4-Scout-Base 的三分之一，但激活参数量是后者的两倍。

针对 Qwen3-14B-Base 和 Qwen3-30B-A3B-Base 的评估，我们选取了同规模的基线模型进行对比，包括 Gemma-3-12B Base 和 Qwen2.5-14B Base。同样地，我们也引入了两个强大的基线模型：（1）Qwen2.5-Turbo，其拥有 420 亿参数和 60 亿激活参数（请注意，其激活参数量是 Qwen3-30B-A3B-Base 的两倍）。（2）Qwen2.5-32B-Base，其激活参数量是 Qwen3-30B-A3B 的 11 倍，也是 Qwen3-14B 的两倍多。结果如表 5 所示，我们可以得出以下结论：

- （1）对比同规模模型：Qwen3-14B-Base 在全部 15 个基准测试中，表现均显著优于 Qwen2.5-14B-Base 和 Gemma-3-12B-Base。
- （2）对比更大规模模型：同样地，Qwen3-14B-Base 在参数量不足一半的情况下，其表现也与 Qwen2.5-32B-Base 相当，极具竞争力。
- （3）MoE 模型效率：Qwen3-30B-A3B 仅使用了 1/5 的激活非嵌入参数，就在所有任务中显著超越了 Qwen2.5-14B-Base，并达到了与 Qwen3-14B-Base 和 Qwen2.5-32B-Base 相当的性能，这为我们带来了推理和训练成本上的显著优势。

Qwen3-8B / 4B / 1.7B / 0.6B-Base

对于面向端侧（边缘端）的模型，我们选取了同规模的 Qwen2.5、Llama-3 和 Gemma-3 基础模型作为基线。结果如表 6、表 7 和表 8 所示。所有的 Qwen3-8B / 4B / 1.7B / 0.6B-Base 模型在几乎所有基准测试中都继续保持了强劲的性能。值得注意的是，Qwen3-8B / 4B / 1.7B-Base 模型在超过一半的基准测试中甚至超越了规模更大的 Qwen2.5-14B / 7B / 3B-Base 模型，尤其是在 STEM（科学、技术、工程和数学）相关及编程基准测试中表现突出，这充分反映了 Qwen3 模型的显著提升。

表 3：Qwen3-235B-A22B-Base 与其他具有代表性的强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。

|                    | Qwen2.5-72B<br>Base | Qwen2.5-Plus<br>Base | Llama-4-Maverick<br>Base | DeepSeek-V3<br>Base | Qwen3-235B-A22B<br>Base |
|--------------------|---------------------|----------------------|--------------------------|---------------------|-------------------------|
| Architecture       | Dense               | MoE                  | MoE                      | MoE                 | MoE                     |
| # Total Params     | 72B                 | 271B                 | 402B                     | 671B                | 235B                    |
| # Activated Params | 72B                 | 37B                  | 17B                      | 37B                 | 22B                     |
| General Tasks      |                     |                      |                          |                     |                         |
| MMLU               | 86.06               | 85.02                | 85.16                    | <u>87.19</u>        | <b>87.81</b>            |
| MMLU-Redux         | 83.91               | 82.69                | 84.05                    | <u>86.14</u>        | <b>87.40</b>            |
| MMLU-Pro           | 58.07               | 63.52                | <u>63.91</u>             | 59.84               | <b>68.18</b>            |
| SuperGPQA          | 36.20               | 37.18                | 40.85                    | <u>41.53</u>        | <b>44.06</b>            |
| BBH                | <u>86.30</u>        | 85.60                | 83.62                    | 86.22               | <b>88.87</b>            |
| Math & STEM Tasks  |                     |                      |                          |                     |                         |
| GPQA               | <u>45.88</u>        | 41.92                | 43.94                    | 41.92               | <b>47.47</b>            |
| GSM8K              | 91.50               | <u>91.89</u>         | 87.72                    | 87.57               | <b>94.39</b>            |
| MATH               | 62.12               | 62.78                | <u>63.32</u>             | 62.62               | <b>71.84</b>            |
| Coding Tasks       |                     |                      |                          |                     |                         |
| EvalPlus           | 65.93               | 61.43                | <u>68.38</u>             | 63.75               | <b>77.60</b>            |
| MultiPL-E          | 58.70               | 62.16                | <u>57.28</u>             | <u>62.26</u>        | <b>65.94</b>            |
| MBPP               | <u>76.00</u>        | 74.60                | 75.40                    | 74.20               | <b>81.40</b>            |
| CRUX-O             | 66.20               | 68.50                | <u>77.00</u>             | 76.60               | <b>79.00</b>            |
| Multilingual Tasks |                     |                      |                          |                     |                         |
| MGSM               | 82.40               | 82.21                | 79.69                    | 82.68               | <b>83.53</b>            |
| MMMLU              | 84.40               | 83.49                | 83.09                    | <u>85.88</u>        | <b>86.70</b>            |
| INCLUDE            | 69.05               | 66.97                | <u>73.47</u>             | <b>75.17</b>        | 73.46                   |

表 4：Qwen3-32B-Base 与其他强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。

|                    | Qwen2.5-32B<br>Base | Qwen2.5-72B<br>Base | Gemma-3-27B<br>Base | Llama-4-Scout<br>Base | Qwen3-32B<br>Base |
|--------------------|---------------------|---------------------|---------------------|-----------------------|-------------------|
| Architecture       | Dense               | Dense               | Dense               | MoE                   | Dense             |
| # Total Params     | 32B                 | 72B                 | 27B                 | 109B                  | 32B               |
| # Activated Params | 32B                 | 72B                 | 27B                 | 17B                   | 32B               |
| General Tasks      |                     |                     |                     |                       |                   |
| MMLU               | 83.32               | <b>86.06</b>        | 78.69               | 78.27                 | <u>83.61</u>      |
| MMLU-Redux         | 81.97               | <b>83.91</b>        | 76.53               | 71.09                 | <u>83.41</u>      |
| MMLU-Pro           | 55.10               | <u>58.07</u>        | 52.88               | 56.13                 | <b>65.54</b>      |
| SuperGPQA          | 33.55               | <u>36.20</u>        | 29.87               | 26.51                 | <b>39.78</b>      |
| BBH                | 84.48               | <u>86.30</u>        | 79.95               | 82.40                 | <b>87.38</b>      |
| Math & STEM Tasks  |                     |                     |                     |                       |                   |
| GPQA               | <u>47.97</u>        | 45.88               | 26.26               | 40.40                 | <b>49.49</b>      |
| GSM8K              | <u>92.87</u>        | 91.50               | 81.20               | 85.37                 | <b>93.40</b>      |
| MATH               | <u>57.70</u>        | <b>62.12</b>        | 51.78               | 51.66                 | <u>61.62</u>      |
| Coding Tasks       |                     |                     |                     |                       |                   |
| EvalPlus           | <u>66.25</u>        | 65.93               | 55.78               | 59.90                 | <b>72.05</b>      |
| MultiPL-E          | <u>58.30</u>        | <u>58.70</u>        | 45.03               | 47.38                 | <b>67.06</b>      |
| MBPP               | 73.60               | <u>76.00</u>        | 68.40               | 68.60                 | <b>78.20</b>      |
| CRUX-O             | <u>67.80</u>        | <u>66.20</u>        | 60.00               | 61.90                 | <b>72.50</b>      |
| Multilingual Tasks |                     |                     |                     |                       |                   |
| MGSM               | 78.12               | <u>82.40</u>        | 73.74               | 79.93                 | <b>83.06</b>      |
| MMMLU              | 82.40               | <b>84.40</b>        | 77.62               | 74.83                 | <u>83.83</u>      |
| INCLUDE            | 64.35               | <b>69.05</b>        | <u>68.94</u>        | 68.09                 | <u>67.87</u>      |

表 5：Qwen3-14B-Base、Qwen3-30B-A3B-Base 与其他强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。

|                    | Gemma-3-12B<br>Base | Qwen2.5-14B<br>Base | Qwen2.5-32B<br>Base | Qwen2.5-Turbo<br>Base | Qwen3-14B<br>Base | Qwen3-30B-A3B<br>Base |
|--------------------|---------------------|---------------------|---------------------|-----------------------|-------------------|-----------------------|
| Architecture       | Dense               | Dense               | Dense               | MoE                   | Dense             | MoE                   |
| # Total Params     | 12B                 | 14B                 | 32B                 | 42B                   | 14B               | 30B                   |
| # Activated Params | 12B                 | 14B                 | 32B                 | 6B                    | 14B               | 3B                    |
| General Tasks      |                     |                     |                     |                       |                   |                       |
| MMLU               | 73.87               | 79.66               | <b>83.32</b>        | 79.50                 | 81.05             | <u>81.38</u>          |
| MMLU-Redux         | 70.70               | 76.64               | <b>81.97</b>        | 77.11                 | 79.88             | <u>81.17</u>          |
| MMLU-Pro           | 44.91               | 51.16               | 55.10               | 55.60                 | <u>61.03</u>      | <b>61.49</b>          |
| SuperGPQA          | 24.61               | 30.68               | 33.55               | 31.19                 | <u>34.27</u>      | <b>35.72</b>          |
| BBH                | 74.28               | 78.18               | <b>84.48</b>        | 76.10                 | 81.07             | <u>81.54</u>          |
| Math & STEM Tasks  |                     |                     |                     |                       |                   |                       |
| GPQA               | 31.31               | 32.83               | <b>47.97</b>        | 41.41                 | 39.90             | <u>43.94</u>          |
| GSM8K              | 78.01               | 90.22               | <b>92.87</b>        | 88.32                 | <u>92.49</u>      | 91.81                 |
| MATH               | 44.43               | 55.64               | 57.70               | 55.60                 | <b>62.02</b>      | <u>59.04</u>          |
| Coding Tasks       |                     |                     |                     |                       |                   |                       |
| EvalPlus           | 52.65               | 60.70               | 66.25               | 61.23                 | <b>72.23</b>      | <u>71.45</u>          |
| MultiPL-E          | 43.03               | 54.79               | 58.30               | 53.24                 | <u>61.69</u>      | <b>66.53</b>          |
| MBPP               | 60.60               | 69.00               | <u>73.60</u>        | 67.60                 | 73.40             | <b>74.40</b>          |
| CRUX-O             | 52.00               | 61.10               | <u>67.80</u>        | 60.20                 | <b>68.60</b>      | 67.20                 |
| Multilingual Tasks |                     |                     |                     |                       |                   |                       |
| MGSM               | 64.35               | 74.68               | 78.12               | 70.45                 | <b>79.20</b>      | <u>79.11</u>          |
| MMMLU              | 72.50               | 78.34               | <b>82.40</b>        | 79.76                 | 79.69             | <u>81.46</u>          |
| INCLUDE            | 63.34               | 60.26               | 64.35               | 59.25                 | <u>64.55</u>      | <b>67.00</b>          |

表 6：Qwen3-8B-Base 与其他强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。



|                              | Llama-3-8B<br>Base | Qwen2.5-7B<br>Base | Qwen2.5-14B<br>Base | Qwen3-8B<br>Base |
|------------------------------|--------------------|--------------------|---------------------|------------------|
| Architecture                 | Dense              | Dense              | Dense               | Dense            |
| # Total Params               | 8B                 | 7B                 | 14B                 | 8B               |
| # Activated Params           | 8B                 | 7B                 | 14B                 | 8B               |
| <i>General Tasks</i>         |                    |                    |                     |                  |
| MMLU                         | 66.60              | 74.16              | <b>79.66</b>        | <u>76.89</u>     |
| MMLU-Redux                   | 61.59              | 71.06              | <b>76.64</b>        | <u>76.17</u>     |
| MMLU-Pro                     | 35.36              | 45.00              | <u>51.16</u>        | <b>56.73</b>     |
| SuperGPQA                    | 20.54              | 26.34              | <u>30.68</u>        | <b>31.64</b>     |
| BBH                          | 57.70              | 70.40              | <u>78.18</u>        | <b>78.40</b>     |
| <i>Math &amp; STEM Tasks</i> |                    |                    |                     |                  |
| GPQA                         | 25.80              | <u>36.36</u>       | 32.83               | <b>44.44</b>     |
| GSM8K                        | 55.30              | 85.36              | <b>90.22</b>        | <u>89.84</u>     |
| MATH                         | 20.50              | 49.80              | <u>55.64</u>        | <b>60.80</b>     |
| <i>Coding Tasks</i>          |                    |                    |                     |                  |
| EvalPlus                     | 44.13              | <u>62.18</u>       | 60.70               | <b>67.65</b>     |
| MultiPL-E                    | 31.45              | 50.73              | <u>54.79</u>        | <b>58.75</b>     |
| MBPP                         | 48.40              | 63.40              | <u>69.00</u>        | <b>69.80</b>     |
| CRUX-O                       | 36.80              | 48.50              | <u>61.10</u>        | <b>62.00</b>     |
| <i>Multilingual Tasks</i>    |                    |                    |                     |                  |
| MGSM                         | 38.92              | 63.60              | 74.68               | <b>76.02</b>     |
| MMMLU                        | 59.65              | 71.34              | <b>78.34</b>        | <u>75.72</u>     |
| IINCLUDE                     | 44.94              | 53.98              | <b>60.26</b>        | <u>59.40</u>     |

表 7：Qwen3-4B-Base 与其他强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。

|                              | Gemma-3-4B<br>Base | Qwen2.5-3B<br>Base | Qwen2.5-7B<br>Base | Qwen3-4B<br>Base |
|------------------------------|--------------------|--------------------|--------------------|------------------|
| Architecture                 | Dense              | Dense              | Dense              | Dense            |
| # Total Params               | 4B                 | 3B                 | 7B                 | 4B               |
| # Activated Params           | 4B                 | 3B                 | 7B                 | 4B               |
| <i>General Tasks</i>         |                    |                    |                    |                  |
| MMLU                         | 59.51              | 65.62              | <b>74.16</b>       | <u>72.99</u>     |
| MMLU-Redux                   | 56.91              | 63.68              | <u>71.06</u>       | <b>72.79</b>     |
| MMLU-Pro                     | 29.23              | 34.61              | <u>45.00</u>       | <b>50.58</b>     |
| SuperGPQA                    | 17.68              | 20.31              | <u>26.34</u>       | <b>28.43</b>     |
| BBH                          | 51.70              | 56.30              | <u>70.40</u>       | <b>72.59</b>     |
| <i>Math &amp; STEM Tasks</i> |                    |                    |                    |                  |
| GPQA                         | 24.24              | 26.26              | <u>36.36</u>       | <b>36.87</b>     |
| GSM8K                        | 43.97              | 79.08              | <u>85.36</u>       | <b>87.79</b>     |
| MATH                         | 26.10              | 42.64              | <u>49.80</u>       | <b>54.10</b>     |
| <i>Coding Tasks</i>          |                    |                    |                    |                  |
| EvalPlus                     | 43.23              | 46.28              | <u>62.18</u>       | <b>63.53</b>     |
| MultiPL-E                    | 28.06              | 39.65              | <u>50.73</u>       | <b>53.13</b>     |
| MBPP                         | 46.40              | 54.60              | <u>63.40</u>       | <b>67.00</b>     |
| CRUX-O                       | 34.00              | 36.50              | <u>48.50</u>       | <b>55.00</b>     |
| <i>Multilingual Tasks</i>    |                    |                    |                    |                  |
| MGSM                         | 33.11              | 47.53              | <u>63.60</u>       | <b>67.74</b>     |
| MMMLU                        | 59.62              | 65.55              | <u>71.34</u>       | <b>71.42</b>     |
| INCLUDE                      | 49.06              | 45.90              | <u>53.98</u>       | <b>56.29</b>     |

表 8：Qwen3-1.7B-Base、Qwen3-0.6B-Base 与其他强大开源基线模型的对比。最高分和次高分分别以加粗和下划线标示。

|                              | Qwen2.5-0.5B<br>Base | Qwen3-0.6B<br>Base | Gemma-3-1B<br>Base | Qwen2.5-1.5B<br>Base | Qwen3-1.7B<br>Base |
|------------------------------|----------------------|--------------------|--------------------|----------------------|--------------------|
| Architecture                 | Dense                | Dense              | Dense              | Dense                | Dense              |
| # Total Params               | 0.5B                 | 0.6B               | 1B                 | 1.5B                 | 1.7B               |
| # Activated Params           | 0.5B                 | 0.6B               | 1B                 | 1.5B                 | 1.7B               |
| <i>General Tasks</i>         |                      |                    |                    |                      |                    |
| MMLU                         | 47.50                | 52.81              | 26.26              | <u>60.90</u>         | <b>62.63</b>       |
| MMLU-Redux                   | 45.10                | 51.26              | 25.99              | <u>58.46</u>         | <b>61.66</b>       |
| MMLU-Pro                     | 15.69                | 24.74              | 9.72               | <u>28.53</u>         | <b>36.76</b>       |
| SuperGPQA                    | 11.30                | 15.03              | 7.19               | <u>17.64</u>         | <b>20.92</b>       |
| BBH                          | 20.30                | 41.47              | 28.13              | <u>45.10</u>         | <b>54.47</b>       |
| <i>Math &amp; STEM Tasks</i> |                      |                    |                    |                      |                    |
| GPQA                         | 24.75                | <u>26.77</u>       | 24.75              | 24.24                | <b>28.28</b>       |
| GSM8K                        | 41.62                | 59.59              | 2.20               | <u>68.54</u>         | <b>75.44</b>       |
| MATH                         | 19.48                | 32.44              | 3.66               | <u>35.00</u>         | <b>43.50</b>       |
| <i>Coding Tasks</i>          |                      |                    |                    |                      |                    |
| EvalPlus                     | 31.85                | 36.23              | 8.98               | <u>44.80</u>         | <b>52.70</b>       |
| MultiPL-E                    | 18.70                | 24.58              | 5.15               | <u>33.10</u>         | <b>42.71</b>       |
| MBPP                         | 29.80                | 36.60              | 9.20               | <u>43.60</u>         | <b>55.40</b>       |
| CRUX-O                       | 12.10                | 27.00              | 3.80               | <u>29.60</u>         | <b>36.40</b>       |
| <i>Multilingual Tasks</i>    |                      |                    |                    |                      |                    |
| MGSM                         | 12.07                | 30.99              | 1.74               | <u>32.82</u>         | <b>50.71</b>       |
| MMMLU                        | 31.53                | 50.16              | 26.57              | <u>60.27</u>         | <b>63.27</b>       |
| INCLUDE                      | 24.74                | 34.26              | 25.62              | <u>39.55</u>         | <b>45.57</b>       |

## 4 后训练




图1：Qwen3 系列模型的后训练流程。

Qwen3 的后训练流程是围绕两个核心目标进行战略性设计的：

(1) 思维控制：这涉及集成两种截然不同的模式，即“非思考”模式和“思考”模式。这种设计为用户提供了灵活性，使其可以选择模型是否应该进行推理，并能通过指定思维过程的 Token 预算来控制思考的深度。

(2) 强模型到弱模型的知识蒸馏：其目的是简化和优化轻量级模型的后训练过程。通过利用大规模模型的知识，我们大幅降低了构建小规模模型所需的计算成本和开发工作量。

如图 1 所示，Qwen3 系列的旗舰模型遵循一个复杂的四阶段训练流程。前两个阶段专注于培养模型的“思考”能力，而后两个阶段则旨在将强大的“非思考”功能整合进模型中。

初步实验表明，直接将教师模型输出的 logits 蒸馏到轻量级学生模型中，可以有效提升其性能，同时保持对推理过程的细粒度控制。这种方法消除了为每个小规模模型单独执行详尽的四阶段训练流程

的必要性。它不仅带来了更好的即时性能（表现为更高的 Pass@1 分数），还提升了模型的探索能力（体现在改进的 Pass@64 结果上）。此外，这种方法实现了更高的训练效率，与四阶段训练方法相比，仅需十分之一的 GPU 计算时长。

在接下来的章节中，我们将介绍四阶段训练流程，并对强弱模型蒸馏方法进行详细说明。

#### 4.1 长思维链冷启动

我们首先整理了一个涵盖广泛类别的综合性数据集，包括数学、代码、逻辑推理以及通用 STEM 问题。数据集中的每个问题都配有经过验证的标准答案或基于代码的测试用例。该数据集构成了长思维链训练“冷启动”阶段的基础。

数据集的构建涉及一个严格的两阶段过滤过程：查询过滤和响应过滤。在查询过滤阶段，我们使用 Qwen2.5-72B-Instruct 来识别并剔除不易验证的查询。这包括包含多个子问题的查询，或那些要求通用文本生成的查询。此外，我们还会剔除那些 Qwen2.5-72B-Instruct 无需使用思维链推理即可正确回答的查询。这有助于防止模型依赖表面猜测，并确保仅包含需要深度推理的复杂问题。此外，我们还使用 Qwen2.5-72B-Instruct 为每个查询标注领域，以保持数据集跨领域的均衡分布。

在预留出一个验证查询集后，我们使用 QwQ-32B 为剩余的每个查询生成 N 个候选响应。当 QwQ-32B 一致无法生成正确解决方案时，人工标注员会手动评估响应的准确性。对于那些 Pass@N 为正的查询，我们会进一步应用严格的过滤标准，剔除那些：(1) 最终答案错误，(2) 包含大量重复，(3) 明显表现出猜测而非充分推理，(4) 思维过程与总结内容不一致，(5) 语言混合不当或风格转换突兀，或 (6) 被怀疑与潜在验证集项目过于相似的响应。随后，我们使用经过精炼的数据集的一个精心挑选的子集，进行推理模式的初始冷启动训练。此阶段的目标是在模型中灌输基础的推理模式，而不过分强调即时的推理性能。这种方法确保了模型的潜力不会受到限制，从而在随后的强化学习阶段拥有更大的灵活性和提升空间。为了有效实现这一目标，在此准备阶段最好尽量减少训练样本的数量和训练步数。

#### 4.2 推理强化学习

推理强化学习阶段所使用的查询-验证器对必须满足以下四个标准：（1）它们在冷启动阶段未被使用过。

（2）它们对冷启动模型来说是可学习的。（3）它们尽可能具有挑战性。（4）它们涵盖了广泛的子领域。

最终，我们共收集了 3,995 组查询-验证器对，并采用 GRPO 算法来更新模型参数。我们观察到，使用大批次（large batch size）、每个查询进行大量 rollout 采样，以及利用非策略（off-policy）训练来提高样本效率，对训练过程大有裨益。此外，我们还通过控制模型的熵使其稳定增长或保持稳定，解决了如何平衡探索与利用的问题，这对于维持稳定的训练至关重要。因此，在单次强化学习运行过程中，我们在训练奖励和验证集性能上均实现了持续提升，且无需对超参数进行任何人工干预。例如，在总共 170 步的强化学习训练中，Qwen3-235B-A22B 模型在 AIME'24 上的得分从 70.1 提升到了 85.1。

4.3 思维模式融合

思维模式融合阶段的目标是将“非思考”能力整合到先前开发的“思考”模型中。这种方法允许开发者管理和控制推理行为，同时也降低了为思考和非思考任务分别部署独立模型的成本与复杂性。为了实现这一目标，我们在推理强化学习模型的基础上进行了持续的监督微调（SFT），并设计了一个聊天模板来融合这两种模式。此外，我们发现能够熟练处理两种模式的模型在不同的思考预算下均能保持稳定且出色的表现。

SFT 数据的构建

SFT 数据集结合了“思考”和“非思考”两类数据。为了确保额外的 SFT 不会损害第 2 阶段模型的性能，我们使用第 2 阶段模型本身，通过对第 1 阶段的查询进行拒绝采样来生成“思考”数据。另一方面，“非思考”数据经过精心整理，涵盖了多样化的任务，包括代码编写、数学、指令遵循、多语言任务、创意写作、问答和角色扮演。此外，我们采用自动生成的清单来评估“非思考”数据的响应质量。为了增强模型在低资源语言任务上的表现，我们特别增加了翻译任务的比例。

聊天模板设计

为了更好地融合这两种模式，并允许用户动态切换模型的思维过程，我们为 Qwen3 设计了聊天模板，如表 9 所示。具体来说，对于处于“思考模式”和“非思考模式”的样本，我们分别在用户查询或系统消息中引入了 /think 和 /no think 标志。这使得模型能够遵循用户的输入，并相应地选择适当的思维模式。对于“非思考模式”的样本，我们在助手的响应中保留了一个空的思维块。这种设计确保了模型内部格式的一致性，并允许开发者通过在聊天模板中拼接一个空的思维块来阻止模型进行思考行为。默认情况下，模型处于“思考模式”；因此，我们添加了一些“思考模式”的训练样本，其中用户查询不包含 /think 标志。对于更复杂的多轮对话，我们会将多个 /think 和 /no think 标志随机插入到用户的查询中，而模型的响应将遵循遇到的最后一个标志。

表 9：思维模式融合阶段，用于“思考模式”和“非思考模式”的 SFT 数据示例。对于“思考模式”，/think 标志可以省略，因为它代表默认行为。该功能已在 Hugging Face 分词器支持的聊天模板中实现，用户可以通过使用额外的参数 `enable_thinking=False` 来禁用思维模式。

| Thinking Mode                                                                                                                                                                                                                                                                 | Non-Thinking Mode                                                                                                                                                                                                                                 |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>&lt; im_start &gt;user</code><br><code>{query} /think&lt; im_end &gt;</code><br><code>&lt; im_start &gt;assistant</code><br><code>&lt;think&gt;</code><br><code>{thinking_content}</code><br><code>&lt;/think&gt;</code><br><br><code>{response}&lt; im_end &gt;</code> | <code>&lt; im_start &gt;user</code><br><code>{query} /no_think&lt; im_end &gt;</code><br><code>&lt; im_start &gt;assistant</code><br><code>&lt;think&gt;</code><br><br><code>&lt;/think&gt;</code><br><br><code>{response}&lt; im_end &gt;</code> |

思维预算

思维模式融合的另一优势在于，一旦模型学会了在“非思考”和“思考”两种模式下进行响应，它就会自然而然地发展出处理中间情况的能力——即基于不完整的思考生成回答。这一能力为实现对模



型思维过程的预算控制奠定了基础。具体来说，当模型的思考长度达到用户定义的阈值时，我们会手动停止思考过程，并插入停止思考指令：“考虑到用户的时间有限，我必须基于目前的思考直接给出解决方案。\\n\\n”。插入该指令后，模型会基于截至该点积累的推理过程继续生成最终回答。值得注意的是，这种能力并非经过显式训练，而是思维模式融合应用后自然涌现的结果。

#### 4.4 通用强化学习

通用强化学习（General RL）阶段旨在全面提升模型在多样化场景下的能力与稳定性。为了实现这一目标，我们建立了一套复杂的奖励系统，涵盖了 20 多种不同的任务，每种任务都配有定制的评分标准。这些任务专门针对以下核心能力的提升：

- 指令遵循（Instruction Following）：这项能力确保模型能准确理解和遵循用户指令，包括与内容、格式、长度以及使用结构化输出相关的要求，交付符合用户期望的回答。
- 格式遵循（Format Following）：除了明确的指令外，我们还期望模型能遵守特定的格式规范。例如，它应通过在“思考”和“非思考”模式之间切换来正确响应 /think 和 /no think 标志，并在最终输出中始终使用指定的标记（例如 </refer> 和 <|im\_channel|>）来分隔思考部分和回答部分。
- 偏好对齐（Preference Alignment）：对于开放式查询，偏好对齐侧重于提升模型的乐于助人程度、互动性以及风格，最终提供更自然、更令人满意的用户体验。
- 智能体能力（Agent Ability）：这涉及训练模型通过指定接口正确调用工具。在强化学习的 rollout 过程中，允许模型与真实环境执行反馈进行完整的多轮交互循环，从而提高其在长周期决策任务中的表现和稳定性。
- 特定场景能力（Abilities for Specialized Scenarios）：在更专业的场景中，我们设计了针对特定上下文的任务。例如，在检索增强生成（Retrieval-Augmented Generation, RAG）任务中，我们引入了奖励信号来引导模型生成准确且符合上下文的回答，从而最大限度地降低产生幻觉的风险。

为了对上述任务提供反馈，我们采用了三种不同类型的奖励：

（1）基于规则的奖励（Rule-based Reward）：这种奖励机制在推理强化学习阶段已被广泛使用，对于指令遵循和格式遵守等通用任务也同样有效。精心设计的基于规则的奖励可以高精度地评估模型输出的正确性，防止出现“奖励黑客”等问题。

（2）带有参考答案的基于模型的奖励（Model-based Reward with Reference Answer）：在这种方法中，我们为每个查询提供一个参考答案，并提示 Qwen2.5-72B-Instruct 模型基于该参考答案对模型的响应进行评分。这种方法允许更灵活地处理各种任务，无需严格的格式限制，避免了纯基于规则的奖励可能产生的误判（假阴性）。

（3）不带参考答案的基于模型的奖励（Model-based Reward without Reference Answer）：利用人类偏好数据，我们训练了一个奖励模型，为模型的响应分配标量分数。这种不依赖参考答案的方法可以处理更广泛的查询，同时有效增强模型的参与度和帮助性。

#### 4.5 强对弱蒸馏

强模型到弱模型的知识蒸馏流程专门用于优化轻量级模型，涵盖 5 个密集模型（Qwen3-0.6B、1.7B、4B、8B 和 14B）以及一个 MoE 模型（Qwen3-30B-A3B）。这种方法在提升模型性能的同时，有效地赋予了模型强大的模式切换能力。蒸馏过程分为两个主要阶段：

(1) 离策略蒸馏：在初始阶段，我们结合了教师模型在 /think 和 /no think 两种模式下生成的输出，用于响应蒸馏。这有助于轻量级的学生模型发展基本的推理技能以及在不同思维模式之间切换的能力，为下一阶段的在策略训练奠定了坚实的基础。

(2) 在策略蒸馏：在此阶段，学生模型生成在策略序列进行微调。具体来说，通过采样获取提示词，学生模型以 /think 或 /no think 模式生成响应。随后，通过将学生模型的 logits（未归一化的预测结果）与教师模型（Qwen3-32B 或 Qwen3-235B-A22B）的 logits 进行对齐，以最小化 KL 散度，从而对学生模型进行微调。

#### 4.6 后训练评估

为了全面评估经过指令微调模型的质量，我们采用了自动化基准测试，以评估模型在“思考”和“非思考”两种模式下的表现。这些基准测试被划分为以下几个维度：

##### 通用任务

我们利用包括 MMLU-Redux (Gema et al., 2024)、GPQA-Diamond (Rein et al., 2023)、C-Eval (Huang et al., 2023) 和 LiveBench (2024-11-25) (White et al., 2024) 在内的基准测试集。对于 GPQA-Diamond，我们对每个查询采样 10 次，并报告平均准确率。

##### 对齐任务

为了评估模型与人类偏好的对齐程度，我们采用了一系列专门的基准测试。对于指令遵循表现，我们报告 IFEval (Zhou et al., 2023) 的严格提示准确率。为了评估在通用话题上与人类偏好的对齐情况，我们利用 Arena-Hard (Li et al., 2024) 和 AlignBench v1.1 (Liu et al., 2023b)。对于写作任务，我们依靠 Creative Writing V3 (Paech, 2024) 和 WritingBench (Wu et al., 2025) 来评估模型的熟练度和创造力。

##### 数学与文本推理

为了评估数学和逻辑推理技能，我们采用了高水平的数学基准测试，包括 MATH-500 (Lightman et al., 2023)、AIME'24 和 AIME'25 (AIME, 2025)，以及文本推理任务，包括 ZebraLogic (Lin et al., 2025) 和 AutoLogi (Zhu et al., 2025)。**AIME 问题**：每年的题目包括第一部分和第二部分，共 30 道题。对于每道题，我们采样 64 次，并将平均准确率作为最终分数。

##### 智能体与代码

为了测试模型在编码和基于智能体任务上的熟练程度，我们使用 BFCL v3 (Yan et al., 2024)、LiveCodeBench (v5, 2024.10-2025.02) (Jain et al., 2024) 以及来自 CodeElo (Quan et al., 2025) 的 Codeforces 评分。**BFCL**：所有 Qwen3 模型均使用 FC 格式进行评估，同时使用 yarn 将模型部署到

64k 的上下文长度以进行多轮评估。部分基线模型的数据来自 BFCL 榜单，取 FC 格式和 Prompt 格式中的较高分数；对于榜单上未报告的模型，则评估其 Prompt 格式。**LiveCodeBench**：对于非思考模式，我们使用官方推荐的提示；而对于思考模式，我们调整了提示模板，通过移除“除程序外不返回任何内容”的限制，允许模型更自由地进行思考。**性能对比**：为了评估模型与竞赛编程专家之间的性能差距，我们使用 CodeForces 来计算 Elo 评分。在我们的基准测试中，每个问题通过生成多达八次独立的推理尝试来解决。

#### 多语言任务

对于多语言能力，我们评估了四种类型的任务：指令遵循、知识、数学和逻辑推理。**指令遵循**：使用 Multi-IF (He et al., 2024) 进行评估，重点关注 8 种关键语言。**知识评估**：包含两种类型：**区域知识**：通过 INCLUDE (Romanou et al., 2024) 进行评估，涵盖 44 种语言。**通用知识**：使用 MMMLU (OpenAI, 2024) 进行评估，涵盖 14 种语言（未优化的约鲁巴语除外）。对于这两个基准测试，我们仅采样原始数据的 10% 以提高评估效率。**数学任务**：采用涵盖 55 种语言的 MT-AIME2024 (Son et al., 2025) 和包含 18 种语言的 PolyMath (Wang et al., 2025)。**逻辑推理**：使用涵盖 10 种语言的 MlogiQA 进行评估，数据源自 Zhang et al. (2024)。

针对处于思考模式下的所有 Qwen3 模型，我们采用 0.6 的采样温度、0.95 的 top-p 值和 20 的 top-k 值。此外，针对 Creative Writing v3 和 WritingBench，我们应用 1.5 的存在惩罚，以鼓励生成更多多样化的内容。针对处于非思考模式下的 Qwen3 模型，我们将采样超参数配置为：温度 = 0.7，top-p = 0.8，top-k = 20，存在惩罚 = 1.5。对于思考和非思考两种模式，我们都将最大输出长度设置为 32,768 个令牌，但 AIME'24 和 AIME'25 除外，为了提供充足的思考空间，我们将这两个任务的长度扩展至 38,912 个令牌。

#### 评估结果汇总

根据评估结果，我们对最终版 Qwen3 模型总结了以下几个关键结论：

(1) 旗舰模型表现卓越：旗舰模型 Qwen3-235B-A22B 在“思考模式”和“非思考模式”下，均在开源模型中展现了最先进的整体性能，超越了 DeepSeek-R1 和 DeepSeek-V3 等强劲基线。同时，Qwen3-235B-A22B 对比 OpenAI-o1、Gemini 2.5-Pro 和 GPT-4o 等闭源领先模型也极具竞争力，彰显了其深厚的推理能力和全面的通用能力。

(2) 旗舰稠密模型优势明显：旗舰稠密模型 Qwen3-32B 在大多数基准测试中均优于我们此前最强的推理模型 QwQ-32B，其表现可与闭源的 OpenAI-o3-mini 相媲美，表明其具备强大的推理能力。此外，Qwen3-32B 在“非思考模式”下表现也极为出色，超越了我们此前的旗舰非推理稠密模型 Qwen2.5-72B-Instruct。

(3) 轻量级模型效能突出：包括 Qwen3-30B-A3B、Qwen3-14B 以及其他更小的稠密模型在内的轻量级模型，其性能始终优于参数量相近或更大的开源模型，证明了我们“强到弱蒸馏”方法的成功。

详细结果如下。

针对我们的旗舰模型 Qwen3-235B-A22B，我们将其与领先的推理型和非推理型模型进行了对比。**推理模式对比**：在“思考模式”下，我们选取 OpenAI-o1、DeepSeek-R1、Grok-3-Beta (Think) 和 Gemini 2.5-Pro 作为推理基线模型。**非推理模式对比**：在“非思考模式”下，我们选取 GPT-4o-2024-11-20、DeepSeek-V3、Qwen2.5-72B-Instruct 和 LLaMA-4-Maverick 作为非推理基线模型。评估结果如表 11 和表 12 所示：

(1) **思考模式表现**：从表 11 可以看出，Qwen3-235B-A22B（思考模式）仅激活了 60% 的参数，总参数量仅为 35%，但在 23 项基准测试中的 17 项上表现优于 DeepSeek-R1，尤其是在对推理能力要求较高的任务（如数学、智能体和代码）上。这证明了 Qwen3-235B-A22B 在开源模型中具备最先进的推理能力。此外，Qwen3-235B-A22B（思考模式）对比闭源的 OpenAI-o1、Grok-3-Beta (Think) 和 Gemini 2.5-Pro 也极具竞争力，极大地缩小了开源与闭源模型在推理能力上的差距。

(2) **非思考模式表现**：从表 12 可以看出，Qwen3-235B-A22B（非思考模式）超越了其他领先的开源模型，包括 DeepSeek-V3、LLaMA-4-Maverick 以及我们之前的旗舰模型 Qwen2.5-72B-Instruct。此外，在 23 项基准测试中，它有 18 项超越了闭源的 GPT-4o-2024-11-20，这表明即使不借助刻意的“思考过程”，该模型本身也具备极强的内在能力。

表 11：Qwen3-235B-A22B（思维模式）与其他推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                       |                                  | OpenAI-o1    | DeepSeek-R1  | Grok-3-Beta<br>(Think) | Gemini2.5-Pro | Qwen3-235B-A22B |
|-----------------------|----------------------------------|--------------|--------------|------------------------|---------------|-----------------|
|                       | Architecture                     | -            | MoE          | -                      | -             | MoE             |
|                       | # Activated Params               | -            | 37B          | -                      | -             | 22B             |
|                       | # Total Params                   | -            | 671B         | -                      | -             | 235B            |
| General Tasks         | MMLU-Redux                       | 92.8         | 92.9         | -                      | 93.7          | 92.7            |
|                       | GPQA-Diamond                     | 78.0         | 71.5         | 80.2                   | 84.0          | 71.1            |
|                       | C-Eval                           | 85.5         | 91.8         | -                      | 82.9          | 89.6            |
|                       | LiveBench 2024-11-25             | 75.7         | 71.6         | -                      | 82.4          | 77.1            |
| Alignment Tasks       | IFEval strict prompt             | 92.6         | 83.3         | -                      | 89.5          | 83.4            |
|                       | Arena-Hard                       | 92.1         | 92.3         | -                      | 96.4          | 95.6            |
|                       | AlignBench v1.1                  | 8.86         | 8.76         | -                      | 9.03          | 8.94            |
|                       | Creative Writing v3              | 81.7         | 85.5         | -                      | 86.0          | 84.6            |
|                       | WritingBench                     | 7.69         | 7.71         | -                      | 8.09          | 8.03            |
| Math & Text Reasoning | MATH-500                         | 96.4         | 97.3         | -                      | 98.8          | 98.0            |
|                       | AIME'24                          | 74.3         | 79.8         | 83.9                   | 92.0          | 85.7            |
|                       | AIME'25                          | 79.2         | 70.0         | 77.3                   | 86.7          | 81.5            |
|                       | ZebraLogic                       | 81.0         | 78.7         | -                      | 87.4          | 80.3            |
|                       | AutoLogi                         | 79.8         | 86.1         | -                      | 85.4          | 89.0            |
| Agent & Coding        | BFCL v3                          | 67.8         | 56.9         | -                      | 62.9          | 70.8            |
|                       | LiveCodeBench v5                 | 63.9         | 64.3         | 70.6                   | 70.4          | 70.7            |
|                       | CodeForces (Rating / Percentile) | 1891 / 96.7% | 2029 / 98.1% | -                      | 2001 / 97.9%  | 2056 / 98.2%    |
| Multilingual Tasks    | Multi-IF                         | 48.8         | 67.7         | -                      | 77.8          | 71.9            |
|                       | INCLUDE                          | 84.6         | 82.7         | -                      | 85.1          | 78.7            |
|                       | MMMLU 14 languages               | 88.4         | 86.4         | -                      | 86.9          | 84.3            |
|                       | MT-AIME2024                      | 67.4         | 73.5         | -                      | 76.9          | 80.8            |
|                       | PolyMath                         | 38.9         | 47.1         | -                      | 52.2          | 54.7            |
|                       | MLogiQA                          | 75.5         | 73.8         | -                      | 75.6          | 77.1            |

表 12：Qwen3-235B-A22B（非思考模式）与其他非推理基线模型的对比。最高分和第二高分分别以粗体和下划线标出



|                       |                                  | GPT-4o<br>-2024-11-20 | DeepSeek-V3  | Qwen2.5-72B<br>-Instruct | LLaMA-4<br>-Maverick | Qwen3-235B-A22B     |
|-----------------------|----------------------------------|-----------------------|--------------|--------------------------|----------------------|---------------------|
| General Tasks         | Architecture                     | -                     | MoE          | Dense                    | MoE                  | MoE                 |
|                       | # Activated Params               | -                     | 37B          | 72B                      | 17B                  | 22B                 |
|                       | # Total Params                   | -                     | 671B         | 72B                      | 402B                 | 235B                |
|                       | MMLU-Redux                       | 87.0                  | 89.1         | 86.8                     | <b>91.8</b>          | <u>89.2</u>         |
|                       | GPQA-Diamond                     | 46.0                  | 59.1         | 49.0                     | <b>69.8</b>          | <u>62.9</u>         |
| Alignment Tasks       | C-Eval                           | 75.5                  | <b>86.5</b>  | 84.7                     | 83.5                 | <u>86.1</u>         |
|                       | LiveBench 2024-11-25             | 52.2                  | <u>60.5</u>  | 51.4                     | 59.5                 | <b>62.5</b>         |
|                       | IFEval strict prompt             | <u>86.5</u>           | 86.1         | 84.1                     | <b>86.7</b>          | 83.2                |
|                       | Arena-Hard                       | 85.3                  | 85.5         | 81.2                     | 82.7                 | <b>96.1</b>         |
| Math & Text Reasoning | AlignBench v1.1                  | 8.42                  | <u>8.64</u>  | 7.89                     | 7.97                 | <b>8.91</b>         |
|                       | Creative Writing v3              | <b>81.1</b>           | 74.0         | 61.8                     | 61.3                 | <u>80.4</u>         |
|                       | WritingBench                     | <u>7.11</u>           | 6.49         | 7.06                     | 5.46                 | <b>7.70</b>         |
|                       | MATH-500                         | 77.2                  | 90.2         | 83.6                     | <u>90.6</u>          | <b>91.2</b>         |
| Agent & Coding        | AIME'24                          | 11.1                  | <u>39.2</u>  | 18.9                     | 38.5                 | <b>40.1</b>         |
|                       | AIME'25                          | 7.6                   | <b>28.8</b>  | 15.0                     | 15.9                 | <u>24.7</u>         |
|                       | ZebraLogic                       | 27.4                  | <b>42.1</b>  | 26.6                     | <u>40.0</u>          | 37.7                |
|                       | AutoLogi                         | 65.9                  | <u>76.1</u>  | 66.1                     | 75.2                 | <b>83.3</b>         |
| Multilingual Tasks    | BFCL v3                          | <b>72.5</b>           | 57.6         | 63.4                     | 52.9                 | <u>68.0</u>         |
|                       | LiveCodeBench v5                 | 32.7                  | 33.1         | 30.7                     | <b>37.2</b>          | <u>35.3</u>         |
|                       | CodeForces (Rating / Percentile) | 864 / 35.4%           | 1134 / 54.1% | 859 / 35.0%              | 712 / 24.3%          | <b>1387 / 75.7%</b> |
|                       | Multi-IF                         | 65.6                  | 55.6         | 65.3                     | <b>75.5</b>          | <u>70.2</u>         |
| Multilingual Tasks    | INCLUDE                          | 78.8                  | 76.7         | 69.6                     | <b>80.9</b>          | 75.6                |
|                       | MMMLU 14 languages               | 80.3                  | <u>81.1</u>  | 76.9                     | <b>82.5</b>          | 79.8                |
|                       | MT-AIME2024                      | 9.2                   | 20.9         | 12.7                     | <u>27.0</u>          | <b>32.4</b>         |
|                       | PolyMath                         | 13.7                  | 20.4         | 16.9                     | <u>26.1</u>          | <b>27.0</b>         |
|                       | MLogiQA                          | 57.4                  | 58.9         | 59.3                     | <u>59.9</u>          | <b>67.6</b>         |

Qwen3-32B

针对我们的旗舰稠密模型 Qwen3-32B，我们在“思考模式”下选取了 DeepSeek-R1-Distill-Llama-70B、OpenAI-o3-mini (medium) 以及我们此前最强的推理模型 QwQ-32B 作为基线模型；在“非思考模式”下，我们选取了 GPT-4o-mini-2024-07-18、LLaMA-4-Scout 以及我们此前的旗舰模型 Qwen2.5-72B-Instruct 作为基线模型。评估结果如表 13 和表 14 所示。

(1) 思考模式表现：从表 13 可以看出，Qwen3-32B（思考模式）在 23 项基准测试中的 17 项上优于 QwQ-32B，使其成为 320 亿参数级别上新的业界最佳推理模型。此外，Qwen3-32B（思考模式）在对齐能力和多语言表现上也展现出与闭源模型 OpenAI-o3-mini (medium) 相媲美的竞争力。

(2) 非思考模式表现：从表 14 可以看出，Qwen3-32B（非思考模式）在几乎所有基准测试中均展现出优于所有基线模型的性能。特别是，Qwen3-32B（非思考模式）在通用任务上表现与 Qwen2.5-72B-Instruct 相当，但在对齐、多语言以及推理相关任务上具有显著优势，再次证明了 Qwen3 相比我们此前的 Qwen2.5 系列模型在基础能力上的显著提升。

Qwen3-30B-A3B & Qwen3-14B

针对 Qwen3-30B-A3B 和 Qwen3-14B，我们在“思考模式”下将它们与 DeepSeek-R1-Distill-Qwen-32B 和 QwQ-32B 进行比较，而在“非思考模式”下则分别与 Phi-4、Gemma-3-27B-IT 和 Qwen2.5-32B-Instruct 进行比较。评估结果如表 15 和表 16 所示。

(1) 从表 15 可以看出，Qwen3-30B-A3B 和 Qwen3-14B（思考模式）均与 QwQ-32B 具有极强的竞争力，尤其是在推理相关基准测试上。值得注意的是，Qwen3-30B-A3B 以更小的模型规模和不到 1/10 的激活参数量，达到了与 QwQ-32B 相当的性能，证明了我们的“强到弱蒸馏”方法在赋予轻量级模型深度推理能力方面的有效性。

(2) 从表 16 可以看出，Qwen3-30B-A3B 和 Qwen3-14B（非思考模式）在大多数基准测试中均超越

了非推理基线模型。它们以显著更少的激活参数和总参数量，超过了我们之前的 Qwen2.5-32B-Instruct 模型，实现了更高效且更具成本效益的性能表现。

Qwen3-8B / 4B / 1.7B / 0.6B

针对 Qwen3-8B 和 Qwen3-4B，我们在“思考模式”下将它们与 DeepSeek-R1-Distill-Qwen-14B 和 DeepSeek-R1-Distill-Qwen-32B 进行比较，而在“非思考模式”下则分别与 LLaMA-3.1-8B-Instruct、Gemma-3-12B-IT、Qwen2.5-7B-Instruct 和 Qwen2.5-14B-Instruct 进行比较。针对 Qwen3-1.7B 和 Qwen3-0.6B，我们在“思考模式”下将它们与 DeepSeek-R1-Distill-Qwen-1.5B 和 DeepSeek-R1-Distill-Llama-8B 进行比较，而在“非思考模式”下则分别与 Gemma-3-1B-IT、Phi-4-mini、Qwen2.5-1.5B-Instruct 和 Qwen2.5-3B-Instruct 进行比较。Qwen3-8B 和 Qwen3-4B 的评估结果如表 17 和表 18 所示，而 Qwen3-1.7B 和 Qwen3-0.6B 的评估结果如表 19 和表 20 所示。总体而言，这些面向端侧的模型展现出了令人印象深刻的表现，在“思考模式”或“非思考模式”下，其性能均优于参数量更大的基线模型，包括我们之前的 Qwen2.5 系列模型。这些结果再次证明了我们“强到弱蒸馏”方法的有效性，使我们能够以显著降低的成本和精力构建出轻量级的 Qwen3 模型。

表 13：Qwen3-32B（思考模式）与其他推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                          |                                  | DeepSeek-R1<br>-Distill-Llama-70B | QwQ-32B             | OpenAI-o3-mini<br>(medium) | Qwen3-32B    |
|--------------------------|----------------------------------|-----------------------------------|---------------------|----------------------------|--------------|
|                          | Architecture                     | Dense                             | Dense               | -                          | Dense        |
|                          | # Activated Params               | 70B                               | 32B                 | -                          | 32B          |
|                          | # Total Params                   | 70B                               | 32B                 | -                          | 32B          |
| General<br>Tasks         | MMLU-Redux                       | 89.3                              | <u>90.0</u>         | <u>90.0</u>                | <b>90.9</b>  |
|                          | GPQA-Diamond                     | 65.2                              | 65.6                | <b>76.8</b>                | <u>68.4</u>  |
|                          | C-Eval                           | 71.8                              | <b>88.4</b>         | 75.1                       | <u>87.3</u>  |
|                          | LiveBench 2024-11-25             | 54.5                              | <u>72.0</u>         | 70.0                       | <b>74.9</b>  |
| Alignment<br>Tasks       | IFEval strict prompt             | 79.3                              | 83.9                | <b>91.5</b>                | <u>85.0</u>  |
|                          | Arena-Hard                       | 60.6                              | <u>89.5</u>         | 89.0                       | <b>93.8</b>  |
|                          | AlignBench v1.1                  | 6.74                              | <u>8.70</u>         | 8.38                       | <b>8.72</b>  |
|                          | Creative Writing v3              | 62.1                              | <b>82.4</b>         | 74.8                       | <u>81.0</u>  |
|                          | WritingBench                     | 6.08                              | <u>7.86</u>         | 7.52                       | <b>7.90</b>  |
| Math & Text<br>Reasoning | MATH-500                         | 94.5                              | <b>98.0</b>         | <b>98.0</b>                | <u>97.2</u>  |
|                          | AIME'24                          | 70.0                              | 79.5                | <u>79.6</u>                | <b>81.4</b>  |
|                          | AIME'25                          | 56.3                              | 69.5                | <b>74.8</b>                | <u>72.9</u>  |
|                          | ZebraLogic                       | 71.3                              | 76.8                | <b>88.9</b>                | <u>88.8</u>  |
|                          | AutoLogi                         | 83.5                              | <b>88.1</b>         | 86.3                       | <u>87.3</u>  |
| Agent &<br>Coding        | BFCL v3                          | 49.3                              | <u>66.4</u>         | 64.6                       | <b>70.3</b>  |
|                          | LiveCodeBench v5                 | 54.5                              | <u>62.7</u>         | <b>66.3</b>                | <u>65.7</u>  |
|                          | CodeForces (Rating / Percentile) | 1633 / 91.4%                      | <u>1982 / 97.7%</u> | <b>2036 / 98.1%</b>        | 1977 / 97.7% |
| Multilingual<br>Tasks    | Multi-IF                         | 57.6                              | <u>68.3</u>         | 48.4                       | <b>73.0</b>  |
|                          | INCLUDE                          | 62.1                              | <u>69.7</u>         | <u>73.1</u>                | <b>73.7</b>  |
|                          | MMMLU 14 languages               | 69.6                              | <b>80.9</b>         | 79.3                       | <u>80.6</u>  |
|                          | MT-AIME2024                      | 29.3                              | 68.0                | <u>73.9</u>                | <b>75.0</b>  |
|                          | PolyMath                         | 29.4                              | <u>45.9</u>         | 38.6                       | <b>47.4</b>  |
|                          | MLogiQA                          | 60.3                              | <u>75.5</u>         | 71.1                       | <b>76.3</b>  |

表 14：Qwen3-32B（非思考模式）与其他非推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                          |                                  | GPT-4o-mini<br>-2024-07-18 | LLaMA-4<br>-Scout | Qwen2.5-72B<br>-Instruct | Qwen3-32B           |
|--------------------------|----------------------------------|----------------------------|-------------------|--------------------------|---------------------|
|                          | Architecture                     | -                          | MoE               | Dense                    | Dense               |
|                          | # Activated Params               | -                          | 17B               | 72B                      | 32B                 |
|                          | # Total Params                   | -                          | 109B              | 72B                      | 32B                 |
| General<br>Tasks         | MMLU-Redux                       | 81.5                       | <u>86.3</u>       | <b>86.8</b>              | 85.7                |
|                          | GPQA-Diamond                     | 40.2                       | <b>57.2</b>       | 49.0                     | <u>54.6</u>         |
|                          | C-Eval                           | 66.3                       | 78.2              | <b>84.7</b>              | <u>83.3</u>         |
|                          | LiveBench 2024-11-25             | 41.3                       | 47.6              | <u>51.4</u>              | <b>59.8</b>         |
| Alignment<br>Tasks       | IFEval strict prompt             | 80.4                       | <b>84.7</b>       | <u>84.1</u>              | 83.2                |
|                          | Arena-Hard                       | 74.9                       | 70.5              | <u>81.2</u>              | <b>92.8</b>         |
|                          | AlignBench v1.1                  | 7.81                       | 7.49              | <u>7.89</u>              | <b>8.58</b>         |
|                          | Creative Writing v3              | <u>70.3</u>                | 55.0              | 61.8                     | <b>78.3</b>         |
|                          | WritingBench                     | 5.98                       | 5.49              | <u>7.06</u>              | <b>7.54</b>         |
| Math & Text<br>Reasoning | MATH-500                         | 78.2                       | 82.6              | <u>83.6</u>              | <b>88.6</b>         |
|                          | AIME'24                          | 8.1                        | <u>28.6</u>       | 18.9                     | <b>31.0</b>         |
|                          | AIME'25                          | 8.8                        | 10.0              | <u>15.0</u>              | <b>20.2</b>         |
|                          | ZebraLogic                       | 20.1                       | 24.2              | <u>26.6</u>              | <b>29.2</b>         |
|                          | AutoLogi                         | 52.6                       | 56.8              | <u>66.1</u>              | <b>78.5</b>         |
| Agent &<br>Coding        | BFCL v3                          | <b>64.0</b>                | 45.4              | <u>63.4</u>              | 63.0                |
|                          | LiveCodeBench v5                 | 27.9                       | 29.8              | <u>30.7</u>              | <b>31.3</b>         |
|                          | CodeForces (Rating / Percentile) | <u>1113 / 52.6%</u>        | 981 / 43.7%       | 859 / 35.0%              | <b>1353 / 71.0%</b> |
| Multilingual<br>Tasks    | Multi-IF                         | 62.4                       | 64.2              | <u>65.3</u>              | <b>70.7</b>         |
|                          | INCLUDE                          | 66.0                       | <b>74.1</b>       | 69.6                     | <u>70.9</u>         |
|                          | MMMLU 14 languages               | 72.1                       | <b>77.5</b>       | <u>76.9</u>              | <u>76.5</u>         |
|                          | MT-AIME2024                      | 6.0                        | <u>19.1</u>       | 12.7                     | <b>24.1</b>         |
|                          | PolyMath                         | 12.0                       | <u>20.9</u>       | 16.9                     | <b>22.5</b>         |
|                          | MLogiQA                          | 42.6                       | 53.9              | <u>59.3</u>              | <b>62.9</b>         |

表 15：Qwen3-30B-A3B / Qwen3-14B（思考模式）与其他推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                          |                                  | DeepSeek-R1<br>-Distill-Qwen-32B | QwQ-32B             | Qwen3-14B    | Qwen3-30B-A3B       |
|--------------------------|----------------------------------|----------------------------------|---------------------|--------------|---------------------|
|                          | Architecture                     | Dense                            | Dense               | Dense        | MoE                 |
|                          | # Activated Params               | 32B                              | 32B                 | 14B          | 3B                  |
|                          | # Total Params                   | 32B                              | 32B                 | 14B          | 30B                 |
| General<br>Tasks         | MMLU-Redux                       | 88.2                             | <b>90.0</b>         | 88.6         | <u>89.5</u>         |
|                          | GPQA-Diamond                     | 62.1                             | <u>65.6</u>         | 64.0         | <b>65.8</b>         |
|                          | C-Eval                           | 82.2                             | <b>88.4</b>         | 86.2         | <u>86.6</u>         |
|                          | LiveBench 2024-11-25             | 45.6                             | <u>72.0</u>         | 71.3         | <b>74.3</b>         |
| Alignment<br>Tasks       | IFEval strict prompt             | 72.5                             | 83.9                | <u>85.4</u>  | <b>86.5</b>         |
|                          | Arena-Hard                       | 60.8                             | 89.5                | <b>91.7</b>  | <u>91.0</u>         |
|                          | AlignBench v1.1                  | 7.25                             | <b>8.70</b>         | 8.56         | <b>8.70</b>         |
|                          | Creative Writing v3              | 55.0                             | <b>82.4</b>         | <u>80.3</u>  | 79.1                |
|                          | WritingBench                     | 6.13                             | <b>7.86</b>         | <u>7.80</u>  | 7.70                |
| Math & Text<br>Reasoning | MATH-500                         | 94.3                             | <b>98.0</b>         | <u>96.8</u>  | <b>98.0</b>         |
|                          | AIME'24                          | 72.6                             | <u>79.5</u>         | 79.3         | <b>80.4</b>         |
|                          | AIME'25                          | 49.6                             | 69.5                | <u>70.4</u>  | <b>70.9</b>         |
|                          | ZebraLogic                       | 69.6                             | 76.8                | <u>88.5</u>  | <b>89.5</b>         |
|                          | AutoLogi                         | 74.6                             | 88.1                | <b>89.2</b>  | <u>88.7</u>         |
| Agent &<br>Coding        | BFCL v3                          | 53.5                             | 66.4                | <b>70.4</b>  | <u>69.1</u>         |
|                          | LiveCodeBench v5                 | 54.5                             | <u>62.7</u>         | <b>63.5</b>  | 62.6                |
|                          | CodeForces (Rating / Percentile) | 1691 / 93.4%                     | <b>1982 / 97.7%</b> | 1766 / 95.3% | <u>1974 / 97.7%</u> |
| Multilingual<br>Tasks    | Multi-IF                         | 31.3                             | 68.3                | <b>74.8</b>  | <u>72.2</u>         |
|                          | INCLUDE                          | 68.0                             | 69.7                | <u>71.7</u>  | <b>71.9</b>         |
|                          | MMMLU 14 languages               | <u>78.6</u>                      | <b>80.9</b>         | 77.9         | 78.4                |
|                          | MT-AIME2024                      | 44.6                             | 68.0                | <u>73.3</u>  | <b>73.9</b>         |
|                          | PolyMath                         | 35.1                             | <u>45.9</u>         | 45.8         | <b>46.1</b>         |
|                          | MLogiQA                          | 63.3                             | <b>75.5</b>         | <u>71.1</u>  | 70.1                |

表 16：Qwen3-30B-A3B / Qwen3-14B（非思考模式）与其他非推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                          |                                  | Phi-4               | Gemma-3<br>-27B-IT | Qwen2.5-32B<br>-Instruct | Qwen3-14B    | Qwen3-30B-A3B       |
|--------------------------|----------------------------------|---------------------|--------------------|--------------------------|--------------|---------------------|
|                          | Architecture                     | Dense               | Dense              | Dense                    | Dense        | MoE                 |
|                          | # Activated Params               | 14B                 | 27B                | 32B                      | 14B          | 3B                  |
|                          | # Total Params                   | 14B                 | 27B                | 32B                      | 14B          | 30B                 |
| General<br>Tasks         | MMLU-Redux                       | <b>85.3</b>         | 82.6               | 83.9                     | 82.0         | <u>84.1</u>         |
|                          | GPQA-Diamond                     | <b>56.1</b>         | 42.4               | 49.5                     | <u>54.8</u>  | <u>54.8</u>         |
|                          | C-Eval                           | 66.9                | 66.6               | 80.6                     | <u>81.0</u>  | <b>82.9</b>         |
|                          | LiveBench 2024-11-25             | 41.6                | 49.2               | 50.0                     | <u>59.6</u>  | <u>59.4</u>         |
| Alignment<br>Tasks       | IFEval strict prompt             | 62.1                | 80.6               | 79.5                     | <b>84.8</b>  | <u>83.7</u>         |
|                          | Arena-Hard                       | 75.4                | 86.8               | 74.5                     | 86.3         | <b>88.0</b>         |
|                          | AlignBench v1.1                  | 7.61                | 7.80               | 7.71                     | <u>8.52</u>  | <b>8.55</b>         |
|                          | Creative Writing v3              | 51.2                | <b>82.0</b>        | 54.6                     | <u>73.1</u>  | 68.1                |
|                          | WritingBench                     | 5.73                | <u>7.22</u>        | 5.90                     | <u>7.24</u>  | <u>7.22</u>         |
| Math & Text<br>Reasoning | MATH-500                         | 80.8                | <b>90.0</b>        | 84.6                     | <b>90.0</b>  | <u>89.8</u>         |
|                          | AIME'24                          | 22.9                | <u>32.6</u>        | 18.8                     | 31.7         | <b>32.8</b>         |
|                          | AIME'25                          | 17.3                | <b>24.0</b>        | 12.8                     | <u>23.3</u>  | 21.6                |
|                          | ZebraLogic                       | 32.3                | 24.6               | 26.1                     | <u>33.0</u>  | <b>33.2</b>         |
|                          | AutoLogi                         | 66.2                | 64.2               | 65.5                     | <u>82.0</u>  | <u>81.5</u>         |
| Agent &<br>Coding        | BFCL v3                          | 47.0                | 59.1               | <b>62.8</b>              | <u>61.5</u>  | 58.6                |
|                          | LiveCodeBench v5                 | 25.2                | 26.9               | 26.4                     | <u>29.0</u>  | <b>29.8</b>         |
|                          | CodeForces (Rating / Percentile) | <b>1280 / 65.3%</b> | 1063 / 49.3%       | 903 / 38.2%              | 1200 / 58.6% | <u>1267 / 64.1%</u> |
| Multilingual<br>Tasks    | Multi-IF                         | 49.5                | 69.8               | 63.2                     | <b>72.9</b>  | <u>70.8</u>         |
|                          | INCLUDE                          | 65.3                | <b>71.4</b>        | 67.5                     | <u>67.8</u>  | <u>67.8</u>         |
|                          | MMMLU 14 languages               | <u>74.7</u>         | <b>76.1</b>        | 74.2                     | <u>72.6</u>  | 73.8                |
|                          | MT-AIME2024                      | 13.1                | 23.0               | 15.3                     | <u>23.2</u>  | <b>24.6</b>         |
|                          | PolyMath                         | 17.4                | 20.3               | 18.3                     | <u>22.0</u>  | <b>23.3</b>         |
|                          | MLogiQA                          | 53.1                | <u>58.5</u>        | 58.0                     | <b>58.9</b>  | 53.3                |

表 17：Qwen3-8B / Qwen3-4B（思考模式）与其他推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。

|                          |                                  | DeepSeek-R1<br>-Distill-Qwen-14B | DeepSeek-R1<br>-Distill-Qwen-32B | Qwen3-4B     | Qwen3-8B            |
|--------------------------|----------------------------------|----------------------------------|----------------------------------|--------------|---------------------|
|                          | Architecture                     | Dense                            | Dense                            | Dense        | Dense               |
|                          | # Activated Params               | 14B                              | 32B                              | 4B           | 8B                  |
|                          | # Total Params                   | 14B                              | 32B                              | 4B           | 8B                  |
| General<br>Tasks         | MMLU-Redux                       | 84.1                             | <b>88.2</b>                      | 83.7         | <u>87.5</u>         |
|                          | GPQA-Diamond                     | 59.1                             | <b>62.1</b>                      | 55.9         | <u>62.0</u>         |
|                          | C-Eval                           | 78.1                             | <u>82.2</u>                      | 77.5         | <b>83.4</b>         |
|                          | LiveBench 2024-11-25             | 52.3                             | 45.6                             | <u>63.6</u>  | <b>67.1</b>         |
| Alignment<br>Tasks       | IFEval strict prompt             | 72.6                             | 72.5                             | <u>81.9</u>  | <b>85.0</b>         |
|                          | Arena-Hard                       | 48.0                             | 60.8                             | <u>76.6</u>  | <b>85.8</b>         |
|                          | AlignBench v1.1                  | 7.43                             | 7.25                             | <u>8.30</u>  | <b>8.46</b>         |
|                          | Creative Writing v3              | 54.2                             | 55.0                             | <u>61.1</u>  | <b>75.0</b>         |
|                          | WritingBench                     | 6.03                             | 6.13                             | <u>7.35</u>  | <b>7.59</b>         |
| Math & Text<br>Reasoning | MATH-500                         | 93.9                             | 94.3                             | <u>97.0</u>  | <b>97.4</b>         |
|                          | AIME'24                          | 69.7                             | 72.6                             | <u>73.8</u>  | <b>76.0</b>         |
|                          | AIME'25                          | 44.5                             | 49.6                             | <u>65.6</u>  | <b>67.3</b>         |
|                          | ZebraLogic                       | 59.1                             | 69.6                             | <u>81.0</u>  | <b>84.8</b>         |
|                          | AutoLogi                         | 78.6                             | 74.6                             | <u>87.9</u>  | <b>89.1</b>         |
| Agent &<br>Coding        | BFCL v3                          | 49.5                             | 53.5                             | <u>65.9</u>  | <b>68.1</b>         |
|                          | LiveCodeBench v5                 | 45.5                             | <u>54.5</u>                      | 54.2         | <b>57.5</b>         |
|                          | CodeForces (Rating / Percentile) | 1574 / 89.1%                     | <u>1691 / 93.4%</u>              | 1671 / 92.8% | <b>1785 / 95.6%</b> |
| Multilingual<br>Tasks    | Multi-IF                         | 29.8                             | 31.3                             | <u>66.3</u>  | <b>71.2</b>         |
|                          | INCLUDE                          | 59.7                             | <b>68.0</b>                      | 61.8         | <u>67.8</u>         |
|                          | MMMLU 14 languages               | 73.8                             | <b>78.6</b>                      | 69.8         | <u>74.4</u>         |
|                          | MT-AIME2024                      | 33.7                             | 44.6                             | <u>60.7</u>  | <b>65.4</b>         |
|                          | PolyMath                         | 28.6                             | 35.1                             | <u>40.0</u>  | <b>42.7</b>         |
|                          | MLogiQA                          | 53.6                             | 63.3                             | <u>65.9</u>  | <b>69.0</b>         |

表 18：Qwen3-8B / Qwen3-4B（非思考模式）与其他非推理基线模型的对比。最高分和第二高分分别以粗体和下划线标示。



|                          |                                  | LLaMA-3.1-8B<br>-Instruct | Gemma-3<br>-12B-IT | Qwen2.5-7B<br>-Instruct | Qwen2.5-14B<br>-Instruct | Qwen3-4B    | Qwen3-8B            |
|--------------------------|----------------------------------|---------------------------|--------------------|-------------------------|--------------------------|-------------|---------------------|
|                          | Architecture                     | Dense                     | Dense              | Dense                   | Dense                    | Dense       | Dense               |
|                          | # Activated Params               | 8B                        | 12B                | 7B                      | 14B                      | 4B          | 8B                  |
|                          | # Total Params                   | 8B                        | 12B                | 7B                      | 14B                      | 4B          | 8B                  |
| General<br>Tasks         | MMLU-Redux                       | 61.7                      | 77.8               | 75.4                    | <b>80.0</b>              | 77.3        | <u>79.5</u>         |
|                          | GPQA-Diamond                     | 32.8                      | 40.9               | 36.4                    | <b>45.5</b>              | <u>41.7</u> | 39.3                |
|                          | C-Eval                           | 52.0                      | 61.1               | 76.2                    | <b>78.0</b>              | 72.2        | <u>77.9</u>         |
|                          | LiveBench 2024-11-25             | 26.0                      | 43.7               | 34.9                    | 42.2                     | <u>48.4</u> | <b>53.5</b>         |
| Alignment<br>Tasks       | IFEval strict prompt             | 75.0                      | 80.2               | 71.2                    | 81.0                     | <u>81.2</u> | <b>83.0</b>         |
|                          | Arena-Hard                       | 30.1                      | <b>82.6</b>        | 52.0                    | 68.3                     | 66.2        | <u>79.6</u>         |
|                          | AlignBench v1.1                  | 6.01                      | 7.77               | 7.27                    | 7.67                     | <u>8.10</u> | <b>8.38</b>         |
|                          | Creative Writing v3              | 52.8                      | <b>79.9</b>        | 49.8                    | 55.8                     | 53.6        | <u>64.5</u>         |
|                          | WritingBench                     | 4.57                      | <u>7.05</u>        | 5.82                    | 5.93                     | 6.85        | 7.15                |
| Math & Text<br>Reasoning | MATH-500                         | 54.8                      | <u>85.6</u>        | 77.6                    | 83.4                     | 84.8        | <b>87.4</b>         |
|                          | AIME'24                          | 6.3                       | 22.4               | 9.1                     | 15.2                     | <u>25.0</u> | <b>29.1</b>         |
|                          | AIME'25                          | 2.7                       | 18.8               | 12.1                    | 13.6                     | <u>19.1</u> | <b>20.9</b>         |
|                          | ZebraLogic                       | 12.8                      | 17.8               | 12.0                    | 19.7                     | <b>35.2</b> | <u>26.7</u>         |
|                          | AutoLogi                         | 30.9                      | 58.9               | 42.9                    | 57.4                     | <u>76.3</u> | <b>76.5</b>         |
| Agent &<br>Coding        | BFCL v3                          | 49.6                      | 50.6               | 55.8                    | <u>58.7</u>              | 57.6        | <b>60.2</b>         |
|                          | LiveCodeBench v5                 | 10.8                      | <b>25.7</b>        | 14.4                    | 21.9                     | 21.3        | <u>22.8</u>         |
|                          | CodeForces (Rating / Percentile) | 473 / 14.9%               | 462 / 14.7%        | 191 / 0.0%              | 904 / 38.3%              | 842 / 33.7% | <b>1110 / 52.4%</b> |
| Multilingual<br>Tasks    | Multi-IF                         | 52.1                      | <u>65.6</u>        | 47.7                    | 55.5                     | 61.3        | <b>69.2</b>         |
|                          | INCLUDE                          | 34.0                      | <b>65.3</b>        | 53.6                    | <u>63.5</u>              | 53.8        | 62.5                |
|                          | MMMLU 14 languages               | 44.4                      | <u>70.0</u>        | 61.4                    | <b>70.3</b>              | 61.7        | 66.9                |
|                          | MT-AIME2024                      | 0.4                       | <b>16.7</b>        | 5.5                     | 8.5                      | 13.9        | <u>16.6</u>         |
|                          | PolyMath                         | 5.8                       | <u>17.6</u>        | 11.9                    | 15.0                     | 16.6        | <b>18.8</b>         |
|                          | MLogiQA                          | 41.9                      | <b>54.5</b>        | 49.5                    | 51.3                     | 49.9        | <u>51.4</u>         |

表 19：Qwen3-1.7B / Qwen3-0.6B（思考模式）与其他推理基线模型的对比。最高分和第二高分分别以**粗体**和下划线标示。

|                          |                      | DeepSeek-R1<br>-Distill-Qwen-1.5B | DeepSeek-R1<br>-Distill-Llama-8B | Qwen3-0.6B  | Qwen3-1.7B  |
|--------------------------|----------------------|-----------------------------------|----------------------------------|-------------|-------------|
|                          | Architecture         | Dense                             | Dense                            | Dense       | Dense       |
|                          | # Activated Params   | 1.5B                              | 8B                               | 0.6B        | 1.7B        |
|                          | # Total Params       | 1.5B                              | 8B                               | 0.6B        | 1.7B        |
| General<br>Tasks         | MMLU-Redux           | 45.4                              | <u>66.4</u>                      | 55.6        | <b>73.9</b> |
|                          | GPQA-Diamond         | 33.8                              | <b>49.0</b>                      | 27.9        | <u>40.1</u> |
|                          | C-Eval               | 27.1                              | <u>50.4</u>                      | <u>50.4</u> | <b>68.1</b> |
|                          | LiveBench 2024-11-25 | 24.9                              | <u>40.6</u>                      | 30.3        | <b>51.1</b> |
| Alignment<br>Tasks       | IFEval strict prompt | 39.9                              | 59.0                             | <u>59.2</u> | <b>72.5</b> |
|                          | Arena-Hard           | 4.5                               | <u>17.6</u>                      | 8.5         | <b>43.1</b> |
|                          | AlignBench v1.1      | 5.00                              | <u>6.24</u>                      | 6.10        | <b>7.60</b> |
|                          | Creative Writing v3  | 16.4                              | <b>51.1</b>                      | 30.6        | <u>48.0</u> |
|                          | WritingBench         | 4.03                              | 5.42                             | <u>5.61</u> | <b>7.02</b> |
| Math & Text<br>Reasoning | MATH-500             | 83.9                              | <u>89.1</u>                      | 77.6        | <b>93.4</b> |
|                          | AIME'24              | 28.9                              | <b>50.4</b>                      | 10.7        | <u>48.3</u> |
|                          | AIME'25              | 22.8                              | <u>27.8</u>                      | 15.1        | <b>36.8</b> |
|                          | ZebraLogic           | 4.9                               | <u>37.1</u>                      | 30.3        | <b>63.2</b> |
|                          | AutoLogi             | 19.1                              | <u>63.4</u>                      | 61.6        | <b>83.2</b> |
| Agent &<br>Coding        | BFCL v3              | 14.0                              | 21.5                             | <u>46.4</u> | <b>56.6</b> |
|                          | LiveCodeBench v5     | 13.2                              | <b>42.5</b>                      | 12.3        | <u>33.2</u> |
| Multilingual<br>Tasks    | Multi-IF             | 13.3                              | 27.0                             | <u>36.1</u> | <b>51.2</b> |
|                          | INCLUDE              | 21.9                              | 34.5                             | <u>35.9</u> | <b>51.8</b> |
|                          | MMMLU 14 languages   | 27.3                              | 40.1                             | <u>43.1</u> | <b>59.1</b> |
|                          | MT-AIME2024          | 12.4                              | <u>13.2</u>                      | 7.8         | <b>36.1</b> |
|                          | PolyMath             | <u>14.5</u>                       | 10.8                             | 11.4        | <b>25.2</b> |
|                          | MLogiQA              | 29.0                              | 32.8                             | <u>40.9</u> | <b>56.0</b> |

表 20：Qwen3-1.7B / Qwen3-0.6B（非思考模式）与其他非推理基线模型的对比。最高分和第二高分分别以**粗体**和下划线标示。

|                          |                      | Gemma-3<br>-1B-IT | Phi-4-mini  | Qwen2.5-1.5B<br>-Instruct | Qwen2.5-3B<br>-Instruct | Qwen3-0.6B  | Qwen3-1.7B  |
|--------------------------|----------------------|-------------------|-------------|---------------------------|-------------------------|-------------|-------------|
|                          | Architecture         | Dense             | Dense       | Dense                     | Dense                   | Dense       | Dense       |
|                          | # Activated Params   | 1.0B              | 3.8B        | 1.5B                      | 3.1B                    | 0.6B        | 1.7B        |
|                          | # Total Params       | 1.0B              | 3.8B        | 1.5B                      | 3.1B                    | 0.6B        | 1.7B        |
| General<br>Tasks         | MMLU-Redux           | 33.3              | <b>67.9</b> | 50.7                      | <b>64.4</b>             | 44.6        | <b>64.4</b> |
|                          | GPQA-Diamond         | 19.2              | 25.2        | 29.8                      | <b>30.3</b>             | 22.9        | 28.6        |
|                          | C-Eval               | 28.5              | 40.0        | 53.3                      | <b>68.2</b>             | 42.6        | <b>61.0</b> |
|                          | LiveBench 2024-11-25 | 14.4              | <b>25.3</b> | 18.0                      | 23.8                    | 21.8        | <b>35.6</b> |
| Alignment<br>Tasks       | IFEval strict prompt | 54.5              | <b>68.6</b> | 42.5                      | 58.2                    | 54.5        | <b>68.2</b> |
|                          | Arena-Hard           | 17.8              | <b>32.8</b> | 9.0                       | 23.7                    | 6.5         | <b>36.9</b> |
|                          | AlignBench v1.1      | 5.3               | 6.00        | 5.60                      | <b>6.49</b>             | 5.60        | <b>7.20</b> |
|                          | Creative Writing v3  | <b>52.8</b>       | 10.3        | 31.5                      | 42.8                    | 28.4        | <b>43.6</b> |
|                          | WritingBench         | 5.18              | 4.05        | 4.67                      | <b>5.55</b>             | 5.13        | <b>6.54</b> |
| Math & Text<br>Reasoning | MATH-500             | 46.4              | <b>67.6</b> | 55.0                      | 67.2                    | 55.2        | <b>73.0</b> |
|                          | AIME'24              | 0.9               | <b>8.1</b>  | 0.9                       | 6.7                     | 3.4         | <b>13.4</b> |
|                          | AIME'25              | 0.8               | <b>5.3</b>  | 0.4                       | 4.2                     | 2.6         | <b>9.8</b>  |
|                          | ZebraLogic           | 1.9               | 2.7         | 3.4                       | <b>4.8</b>              | 4.2         | <b>12.8</b> |
|                          | AutoLogi             | 16.4              | 28.8        | 22.5                      | 29.9                    | <b>37.4</b> | <b>59.8</b> |
|                          |                      |                   |             |                           |                         |             |             |
| Agent &<br>Coding        | BFCL v3              | 16.3              | 31.3        | 47.8                      | <b>50.4</b>             | 44.1        | <b>52.2</b> |
|                          | LiveCodeBench v5     | 1.8               | <b>10.4</b> | 5.3                       | 9.2                     | 3.6         | <b>11.6</b> |
| Multilingual<br>Tasks    | Multi-IF             | 32.8              | <b>40.5</b> | 20.2                      | 32.3                    | 33.3        | <b>44.7</b> |
|                          | INCLUDE              | 32.7              | <b>43.8</b> | 33.1                      | <b>43.8</b>             | 34.4        | <b>42.6</b> |
|                          | MMMLU 14 languages   | 32.5              | <b>51.4</b> | 40.4                      | <b>51.8</b>             | 37.1        | <b>48.3</b> |
|                          | MT-AIME2024          | 0.2               | 0.9         | 0.7                       | <b>1.6</b>              | 1.5         | <b>4.9</b>  |
|                          | PolyMath             | 3.5               | 6.7         | 5.0                       | <b>7.3</b>              | 4.6         | <b>10.3</b> |
|                          | MLogiQA              | 31.8              | 39.5        | <b>40.9</b>               | 39.5                    | 37.3        | <b>41.1</b> |

4.7 讨论

思考预算的有效性

为了验证 Qwen3 能否通过增加思考预算来提升其智能水平，我们在数学、编程和 STEM 领域的四个基准测试上调整了分配的思考预算。所得的扩展曲线如图 2 所示，Qwen3 展现了与分配的思考预算相关的可扩展且平滑的性能提升。此外，我们观察到，如果我们进一步将输出长度扩展到 32K 以上，模型的性能在未来有望得到进一步提升。我们将这一探索留作未来的工作。




图2 Qwen3-235B-A22B 随思考预算变化的性能表现。

我们通过比较从同一策略外蒸馏的 80 亿参数检查点出发，经过蒸馏与直接进行强化学习后的性能及以 GPU 小时衡量的计算成本，来评估策略内蒸馏的有效性 with 效率。为简化比较，我们在此仅关注数学和代码相关的查询。表 21 的总结结果显示，与强化学习相比，蒸馏在性能上显著更优，且仅需约 1/10 的 GPU 小时。此外，从教师模型的 logits 进行蒸馏使学生模型能够扩展其探索空间并增强推理潜力，这一点在蒸馏后 AIME’24 和 AIME’25 基准测试的 pass@64 分数得到提升上得到了印证，而初始检查点则没有此提升。相比之下，强化学习并未带来 pass@64 分数的任何改进。这些观察结果突显了利用更强的教师模型来指导学生模型学习的优势。

表 21：Qwen3-8B 上强化学习与策略内蒸馏的对比。（括号内的数字表示 pass@64 分数。）

| Method                   | AIME’24            | AIME’25            | MATH500     | LiveCodeBench<br>v5 | MMLU<br>-Redux | GPQA<br>-Diamond | GPU<br>Hours |
|--------------------------|--------------------|--------------------|-------------|---------------------|----------------|------------------|--------------|
| Off-policy Distillation  | 55.0 (90.0)        | 42.8 (83.3)        | 92.4        | 42.0                | 86.4           | 55.6             | -            |
| + Reinforcement Learning | 67.6 (90.0)        | 55.5 (83.3)        | 94.8        | 52.9                | 86.9           | 61.3             | 17,920       |
| + On-policy Distillation | <b>74.4 (93.3)</b> | <b>65.5 (86.7)</b> | <b>97.0</b> | <b>60.3</b>         | <b>88.3</b>    | <b>63.3</b>      | 1,800        |

思考模式融合与通用强化学习的效果

为了评估在后训练阶段“思考模式融合”与“通用强化学习”的有效性，我们在 Qwen-32B 模型的各个训练阶段进行了评估。除了前文提到的数据集外，我们还引入了几个内部基准测试来监控其他能力。这些基准测试包括：

- (1) CounterFactQA：包含反事实问题，模型需要识别出这些问题并非事实，并避免生成幻觉性答案。
- (2) LengthCtrl：包含有长度要求的创意写作任务；最终分数基于生成内容长度与目标长度的差异。
- (3) ThinkFollow：涉及多轮对话，其中随机插入了 /think（思考）和 /no think（不思考）指令，以测试模型能否根据用户查询正确切换思考模式。
- (4) ToolUse：评估模型在单轮、多轮及多步骤工具调用过程中的稳定性。分数包括意图识别的准确性、格式准确性和工具调用过程中的参数准确性。

表 22：Qwen3-32B 在经过推理强化学习（第 2 阶段）、思考模式融合（第 3 阶段）和通用强化学习（第 4 阶段）后的性能表现。带有 \* 的基准测试为内部数据集。

|                                |                      | Stage 2      | Stage 3               |              | Stage 4               |                       |
|--------------------------------|----------------------|--------------|-----------------------|--------------|-----------------------|-----------------------|
|                                |                      | Reasoning RL | Thinking Mode Fusion  |              | General RL            |                       |
|                                | Benchmark            | Thinking     | Thinking              | Non-Thinking | Thinking              | Non-Thinking          |
| General Tasks                  | LiveBench 2024-11-25 | 68.6         | 70.9 <sup>+2.3</sup>  | 57.1         | 74.9 <sup>+4.0</sup>  | 59.8 <sup>+2.8</sup>  |
|                                | Arena-Hard           | 86.8         | 89.4 <sup>+2.6</sup>  | 88.5         | 93.8 <sup>+4.4</sup>  | 92.8 <sup>+4.3</sup>  |
|                                | CounterFactQA*       | 50.4         | 61.3 <sup>+10.9</sup> | 64.3         | 68.1 <sup>+6.8</sup>  | 66.4 <sup>+2.1</sup>  |
| Instruction & Format Following | IFEval strict prompt | 73.0         | 78.4 <sup>+5.4</sup>  | 78.4         | 85.0 <sup>+6.6</sup>  | 83.2 <sup>+4.8</sup>  |
|                                | Multi-IF             | 61.4         | 64.6 <sup>+3.2</sup>  | 65.2         | 73.0 <sup>+8.4</sup>  | 70.7 <sup>+5.5</sup>  |
|                                | LengthCtrl*          | 62.6         | 70.6 <sup>+8.0</sup>  | 84.9         | 73.5 <sup>+2.9</sup>  | 87.3 <sup>+2.4</sup>  |
|                                | ThinkFollow*         | -            | 88.7                  |              | 98.9 <sup>+10.2</sup> |                       |
| Agent                          | BFCL v3              | 69.0         | 68.4 <sup>-0.6</sup>  | 61.5         | 70.3 <sup>+1.9</sup>  | 63.0 <sup>+1.5</sup>  |
|                                | ToolUse*             | 63.3         | 70.4 <sup>+7.1</sup>  | 73.2         | 85.5 <sup>+15.1</sup> | 86.5 <sup>+13.3</sup> |
| Knowledge & STEM               | MMLU-Redux           | 91.4         | 91.0 <sup>-0.4</sup>  | 86.7         | 90.9 <sup>-0.1</sup>  | 85.7 <sup>-1.0</sup>  |
|                                | GPQA-Diamond         | 68.8         | 69.0 <sup>+0.2</sup>  | 50.4         | 68.4 <sup>-0.6</sup>  | 54.6 <sup>+4.3</sup>  |
| Math & Coding                  | AIME'24              | 83.8         | 81.9 <sup>-1.9</sup>  | 28.5         | 81.4 <sup>-0.5</sup>  | 31.0 <sup>+2.5</sup>  |
|                                | LiveCodeBench v5     | 68.4         | 67.2 <sup>-1.2</sup>  | 31.1         | 65.7 <sup>-1.5</sup>  | 31.3 <sup>+0.2</sup>  |

结果如表 22 所示，我们可以得出以下结论：

(1) 第 3 阶段 将“非思考模式”整合进了模型，此时模型在前两个阶段的训练后已经具备了“思考能力”。“ThinkFollow”基准测试得分为 88.7，表明模型已经初步具备了在两种模式间切换的能力，尽管偶尔仍会出错。第 3 阶段还增强了模型在“思考模式”下的通用能力和遵循指令的能力，其中“CounterFactQA”得分提高了 10.9 分，“LengthCtrl”得分提高了 8.0 分。

(2) 第 4 阶段 进一步强化了模型在“思考”和“非思考”两种模式下的通用能力、遵循指令能力以及智能体能力。值得注意的是，“ThinkFollow”得分提升至 98.9，确保了模式切换的准确性。

(3) 对于知识、STEM、数学和编程类任务，“思考模式融合”和“通用强化学习”并未带来显著的提升。相反，对于 AIME’24 和 LiveCodeBench 等具有挑战性的任务，经过这两个训练阶段后，模型在“思考模式”下的表现实际上有所下降。我们推测这种性能退化是由于模型在更广泛的通用任务上进行了训练，这可能损害了其处理复杂问题的专业能力。在 Qwen3 的开发过程中，我们选择接受这种性能上的权衡，以增强模型的整体通用性。

## 5 结论

在这份技术报告中，我们介绍了 Qwen 系列的最新版本 Qwen3。Qwen3 同时具备思考模式和非思考模式，允许用户动态管理用于复杂思考任务的 Token 数量。该模型在包含 36 万亿 Token 的海量数据集上进行了预训练，使其能够理解和生成 119 种语言和方言的文本。通过一系列综合评估，Qwen3 在针对预训练模型和后训练模型的各种标准基准测试中均表现出色，涵盖代码生成、数学、推理和智能体等相关任务。

在不久的将来，我们的研究将聚焦于几个关键领域。我们将继续通过使用质量和多样性都更高的数据来扩展预训练规模。同时，我们将致力于改进模型架构和训练方法，以实现有效的压缩、扩展到超长上下文等目标。此外，我们计划增加用于强化学习的计算资源，特别强调从环境反馈中学习的基于智能体的强化学习系统。这将使我们能够构建出能够处理需要推理时长扩展的复杂任务的智能体。



