

AI产品

 Manus

 DeepSeek | 深度求索

 应用功能动态_大模型服务平台百炼(Model Studio)-阿里云帮助中心

5月

日期	功能模块	功能点	功能说明
5月8日	知识库	非结构化知识库支持导入离线HTML文件	支持基于离线HTML文件构建非结构化知识库，详情请参见知识库。

4月

日期	功能模块	功能点	功能说明
4月18日	模型观测	新增高级监控模式	高级监控模式支持分钟级低延时数据刷新，并可记录更详细的模型调用失败信息（如4xx、5xx分别出现次数等）。使用方法请参见模型观测。
4月10日	知识库	新增权重设置功能	当智能体应用同时关联多个知识库时，您可以按信息源的重要性为每个知识库设置权重。系统将优先召回权重更高的知识库中的相关信息。使用方法请参见知识库。
4月9日	MCP	新增MCP市场与MCP管理功能	您可以开通百炼预置的MCP服务或部署自定义MCP服务，并在智能体应用和工作流应用中引用这些 MCP 服务，使应用具备更强大的能力。使用方法请参见MCP快速入门。
4月4日	模型广场	新增qwen-vl-max-2025-04-02模型	视觉理解模型。在解决复杂数学问题方面，准确性显著提高，回复风格面向人类偏好进行大幅调整，尤其是数学、逻辑

			辑推理、知识问答等客观类问题，模型回复详实程度和格式清晰度明显改善，使用方法请参见 视觉理解 。
4月1日	百炼应用	智能体应用 支持QwQ系列模型 不包括插件、流程、音视频交互能力	• QwQ模型具有强大的推理能力，模型会先输出思考过程，再输出回答内容。数学/代码能力（AIME 24/25、LiveCodeBench）及通用指标（IFEval等）达DeepSeek-R1满血版水平，显著优于同源精简版DeepSeek-R1-Distill。

3月

日期	功能模块	功能点	功能说明
3月18日	百炼应用	智能体应用支持qwen-vl-plus-latest、qwen-vl-plus-2025-01-25	• qwen-vl-plus-latest始终等同最新快照版。 • qwen-vl-plus-2025-01-25，又称qwen-vl-plus-0125。此版本属于Qwen2.5-VL系列模型，扩展上下文至128k，显著增强图像和视频的理解能力。
3月6日	推理模型	新增qwq-plus、qwq-plus-latest、qwq-plus-2025-03-05	• 基于 Qwen2.5 模型训练的 QwQ 推理模型，通过强化学习大幅度提升了模型推理能力。模型数学代码等核心指标（AIME 24/25、LiveCodeBench）以及部分通用指标（IFEval、LiveBench等）达到DeepSeek-R1满血版水平。深度思考 (QwQ)
3月6日	开源推理模型	新增qwq-32b	• 基于 Qwen2.5-32B 模型训练的 QwQ 推理模型，通过强化学习大幅度提升了模型推理能力。模型数学代

			码等核心指标（AIME 24/25、LiveCodeBench）以及部分通用指标（IFEval、LiveBench等）达到DeepSeek-R1满血版水平，各指标均显著超过同样基于Qwen2.5-32B的DeepSeek-R1-Distill-Qwen-32B。 深度思考 (QwQ)
3月3日	语音识别/翻译	新增Gummy模型（gummy-realtime-v1、gummy-chat-v1）	Gummy大模型支持实时语音识别与翻译，能够精准识别中、英、日、韩等10种语言。此外，它还支持中、英、日、韩之间的互译，以及其他6种语言单向翻译成中文或英文。使用方法请参见语音识别/翻译。

2月

日期	功能模块	功能点	功能说明
2月25日	模型广场	新增wanx2.1-i2v-turbo模型	相较于wanx2.1-i2v-plus模型，turbo模型生成速度更快，耗时仅为plus模型的三分之一，性价比更高。使用方法请参见图生视频。
2月24日	百炼应用	工作流应用支持批量节点	批量节点是工作流中用于处理批量任务的功能节点，详情请参见批量。
2月18日	百炼应用	智能体应用、工作流应用支持 DeepSeek 系列模型	智能体应用可集成 DeepSeek 系列模型，并结合知识库、长期记忆和 Prompt 模板，构建私有知识问答应用。 工作流应用可使用 DeepSeek 系列模型构建任务型和对话型工作流。

2月14日	全模态	新增 Qwen-Omni 模型 (qwen-omni-turbo、 qwen-omni-turbo-latest、 qwen-omni-turbo-2025-01- 19)	Qwen-Omni 系列模型支持输入多种模态的数据，包括视频、音频、图片、文本，并输出文本。使用方法请参见全模态 (Qwen-Omni)。
2月8日	计费	DeepSeek系列模型计费调整	部分模型由免费体验转为计费，具体请参见文本生成-DeepSeek。
2月7日	计费	qwen-max模型降价	- qwen-max模型的输入价格降低88%，输出价格降低84%： - 实时调用的输入价格从0.02元/千Token降至0.0024元/千Token，输出价格从0.06元/千Token降至0.0096元/千Token。 - Batch调用的输入价格从0.01元/千Token降至0.0012元/千Token，输出价格从0.03元/千Token降至0.0048元/千Token。 - 最新计费详情可参见模型列表。

1月

日期	功能模块	功能点	功能说明
1月27日	文生文	新增DeepSeek模型 (deepseek-v3和deepseek-r1)	DeepSeek系列模型是由深度求索（DeepSeek）公司推出的大语言模型。 - DeepSeek-V3 为混合专家（MoE）模型，671B 参数，激活 37B，在 14.8T Token 上进行了预训练，在长文本、代码、数学、百科、中文能力上表现优秀。 - DeepSeek-R1 在后训练阶段大规模使用了强化学习技术，在仅有极少标注数据的情

			况下，极大提升了模型推理能力，尤其在数学、代码、自然语言推理等任务上。 • 具体请参见文本生成-DeepSeek。
1月27日	视觉理解	新增 Qwen2.5-VL 模型（qwen2.5-vl-3b-instruct、qwen2.5-vl-7b-instruct、qwen2.5-vl-72b-instruct）	• Qwen2.5-VL相对于Qwen2-VL大模型有如下改进： ◦ 在指令跟随、数学计算、代码生成、结构化输出（JSON输出）等方面的能力有显著提升。 ◦ 支持对图像中的文字、图表、布局等视觉内容进行统一解析，并增加了精准定位视觉元素的能力，支持检测框和坐标点的表示方式。 ◦ 结合强大的定位和推理能力，模型的Agent能力大幅增强，可与手机、电脑、机器人等设备集成，根据视觉环境和文本指令进行自动操作。 ◦ 支持对长视频文件（最长10分钟）进行理解，具备秒级的事件时刻定位能力，能理解时间先后和快慢。 • 使用方法请参见视觉理解。
1月27日	文生文	新增 Qwen2.5-Max 模型（qwen-max-2025-01-25）	• 通义千问系列效果最好的模型，代码编写与理解能力、逻辑能力、多语言能力显著提升，回复风格面向人类偏好进行大幅调整，模型回复详实程度和格式清晰度明显改善，内容创作、JSON格式遵循、角色扮演能力定向提升。

			使用方法请参见： 文本生成 。
1月27日	文生文	新增qwen2.5-14b-instruct-1m、qwen2.5-7b-instruct-1m模型	相比于qwen2.5-14b-instruct与qwen2.5-7b-instruct模型，将上下文长度提高到了1000000。使用方法请参见：文本生成。
1月22日	计费	部分通义系列模型价格调整	- qwen2.5-14b-instruct和qwen2.5-7b-instruct模型降价50%： - qwen2.5-14b-instruct模型的输入价格降至0.001元/千Token，输出价格降至0.003元/千Token。 - qwen2.5-7b-instruct模型的输入价格降至0.0005元/千Token，输出价格降至0.001元/千Token。 - qwen2.5-3b-instruct、qwen-vl-72b-instruct模型由免费体验转为计费： - qwen2.5-3b-instruct模型的输入价格为0.0003元/千Token，输出价格为0.0009元/千Token。 - qwen2-vl-72b-instruct模型的输入价格为0.016元/千Token，输出价格为0.048元/千Token。 - 最新计费详情可参见模型列表。
1月22日	图生视频	新增emoji-detect-v1、emoji-v1模型	该模型是人脸动态视频生成模型，可用于表情包制作、视频素材生成等场景。使用方法请参见表情包Emoji快速开始。
1月21日	模型观测	新增模型观测能力	模型观测可以帮助您监测模型的使用情况

			和性能变化，从而更有效地进行问题定位、故障排除和性能优化。使用方法请参见 模型观测 。
1月17日	文生文	新增qwen-plus-2025-01-12模型	相对于qwen-plus-2024-12-20模型，中英文整体能力有提升，中英常识、阅读理解能力提升较为显著，在不同语言、方言、风格之间自然切换的能力有显著改善，中文指令遵循能力显著提升。使用方法请参见qwen-plus-2025-01-12。
1月17日	图生视频	新增wanx2.1-i2v-plus模型	该模型将输入图片作为视频首帧，再根据提示词生成视频。使用方法请参见图生视频。
1月17日	文生图	新增wanx2.0-t2i-turbo模型	擅长质感人像与创意设计，速度中等，性价比高。使用方法请参见文生图V2系列模型。
1月13日	视觉理解	新增qwen-vl-plus-2025-01-02模型	相较于qwen-vl-plus-0809模型，大幅提升指令跟随、图像理解和数学能力。使用方法请参见视觉理解。
1月8日	文生视频	新增wanx2.1-t2v-turbo、wanx2.1-t2v-plus模型	一句话生成视频，生成的视频呈现丰富的艺术风格及影视级画面质感。使用方法请参见文生视频。
1月8日	文生图	新增wanx2.1-t2i-turbo、wanx2.1-t2i-plus模型	全面升级的通义万相-文生图V2模型，使用方法请参见文生图V2版。
1月7日	视觉理解	新增qwen-vl-max-2024-12-30模型	该模型丰富了知识库，图像识别和理解能力进一步提升，能够解析复杂的视觉内容。使用方法请参见视觉理解。

1月2日	语音识别	新增qwen-audio-asr、qwen-audio-asr-latest、qwen-audio-asr-2024-12-04模型	通义千问ASR是基于Qwen-Audio训练，专用于语音识别的模型，目前支持的语言有：中文、英文。使用方法请参见语音识别。
------	------	--	---

🔗 产品动态-一站式智算服务平台 - 天翼云

2025年2月

时间节点	功能名称	功能描述	相关文档
2025/02/26	按Tokens计费模式上线	一站式智算服务平台按Tokens计费模式上线。按Tokens计费是一种灵活的计费模式，您可以通过按量后付费，灵活开通和释放资源，无需提前购买。其优势在于灵活性和节约成本，适用于需要灵活调整资源、业务不稳定或资金有限的场景。	按需计费模式-Tokens

--	--	--

2025年1月

时间节点	功能名称	功能描述	相关文档
2025/01/14	慧聚一站式智算服务平台更名	慧聚一站式智算服务平台更名为：一站式智算服务平台。	一站式智算服务平台

--	--	--

🔗 TI-ONE 训练平台 产品动态_腾讯云

2025年04月 [🔗](#)

动态名称	动态描述	发布时间	相关文档
在线服务	1. [Hot]升级服务鉴权与流量控制功能。支持面向单个服务配置多个密钥，并支持基于Tokens 计数进行大模	2025-04-25	在线服务部署

	型流量控制，可实现精细化的调用方管理和流量控制。 2. 新增支持 gRPC 协议。 3. 支持用户通过环境变量（model_name）自定义调用模型名称。		
数据中心	升级 MLLM 多模态大模型标注能力，新增"位置框"标注组件（ImageBoxList），支持文档解析等场景下的标注。	2025-04-25	schema 配置详细语法
任务式建模	1. 任务式建模支持对接 Git 存储库。 2. 任务式建模支持 COS 挂载（以白名单方式支持）。 3. 修复机器来源从 TIONE 平台购买情况下使用 TIKit 提交训练任务时，指定 VPC 和子网未生效的问题。	2025-04-18	Git 存储库
开发机/任务式建模	任务式建模和开发机新增内置自驾行业通用镜像，支持快速启动 BEVFusion、FastBEV、MapTR、HiVT、UniAD、Sparse4D、PanoOcc 模型训练。	2025-04-02	使用开发机和任务式建模快速训练自驾模型

2025年03月

动态名称	动态描述	发布时间	相关文档
大模型广场	[Hot]全新上架 DeepSeek-V3-0324 模型，支持一键发起训练或部署推理服务。	2025-03-26	大模型广场
数据中心	数据构建内置 Pipeline 支持调用第三方模型服务接口，从而更便捷完成面向模型蒸馏场景的数据萃取过程。	2025-03-25	构建 LLM 精调数据

开发机/任务式建模	1. [Hot]支持 Ray 和 MPI 分布式训练模式，内置于Tilearn-llm0.9-torch2.3-py3.10-cuda12.4-gpu 镜像中； 2. [Hot]全新内置自驾行业通用镜像，支持快速启动 BEVFormer 模型训练； 3. 优化开发机实例停止时的数据持久化提示，提示用户注意数据保存； 4. 资源监控面板支持手动刷新数据。	2025-03-25	使用开发机和任务式建模快速训练自驾模型 分布式训练使用指引
模型评测	1. [Hot]客观评测新增内置开源评测集，可快速启动评测任务； 2. 优化客观评测过程中的状态和进度展示，支持查看模型在单个评测集上的评测进度以及整体评测任务进度，支持查看评测任务剩余时长； 3. 优化客观评测详情页基本信息、结果输出展示，方便用户直观查看任务ID、机器资源、评测结果等信息； 4. 评测 DeeSeek 系列模型时，支持自动为用户推荐所需机器资源，增加评测时选择资源的便利性。	2025-03-25	客观评测
在线服务	1. [Hot]全新上线面向 DeepSeek R1 / V3 模型的 Angel-ACC 加速能力，大幅提升推理性能； 2. [Hot]支持DeepSeek V3 模型部署后的 Function Call 能力； 3. [Hot]服务监控支持首Token延时、Token总调用量、每分钟	2025-03-25	基于内置 Angel-vLLM 镜像进行推理加速 在线服务部署 在线服务调用 在线服务运营

	Token消耗等大模型常用监控指标。 - 大幅降低部署平台内置大模型服务时，将模型文件加载到计算节点的时长； - 部署在线服务时，支持选择来源为 GooseFsx 存储的模型； - 支持关闭服务的公网调用路径（以白名单方式支持）； - 优化服务告警信息，可在告警消息中查看服务 ID、服务名称和服务描述。		
数据中心	- 优化 LLM&MLLM 数据集的全生命周期报错提示，包括新建异常、Schema 解析异常、标注异常等； - 进一步提高 LLM&MLLM 数据集详情预览页的可读性，重点优化多字段、内容复杂、大段文本等情况下的样本展示效果； - 优化 LLM 数据标注操作台的布局，只读组件统一展示在左侧、可编辑组件统一展示在右侧，提升标注页面的空间利用率； - 针对 MLLM 数据标注操作台，新增支持旋转、全屏、放大、缩小等图片操作。	2025-03-14	新建 LLM&MLLM 数据集和标注任务
大模型广场	- 内置的 Hunyuan-Large 大模型升级到 20241116 版本； - 自动驾驶云区域上架大模型广场模块，支持 DeepSeek 系列模型和 Llama 系列模型的	2025-03-14	大模型广场

	一键发起训练和部署。		
资源组管理	[Hot] 支持基于优先级策略的训推一体潮汐调度，同一个资源组内的高优在线服务/训练任务可以抢占低优训练任务的资源。	2025-03-14	调度策略说明

2025年02月

动态名称	动态描述	发布时间	相关文档
开发机	[Hot] Notebook 产品模块升级为开发机，并升级相关特性，更好满足在线编码和调试需求。 1. 新增内置 VSCode WebIDE ； 2. 新增闲置实例自动回收和通知机制； 3. 支持配置环境变量； 4. 实例列表页新增展示镜像信息。 5. 支持修改实例名称。	2025-02-24	闲置回收策略配置指引
任务式建模	优化任务式建模功能和体验细节。 1. 支持在资源组管理页面查看训练任务排队队列； 2. 新增任务开始排队、任务开始运行、任务被停止事件状态通知； 3. 新增遍历排队策略和优先级不抢占策略； 4. 支持修改任务名称。	2025-02-24	资源组管理-查看任务列表 训练任务调度规则说明
在线服务	优化在线服务的功能和稳定性细节问题。 1. 优化新建服务时的重试策略，服务启动失败时默认最多重试启动5次，同时支持用户自定义最大重试次数； 2. 在线服务日志新增支持全文检索，最高可	2025-02-24	-

	加载的日志条数增至100万条； 3. 修复直接登录在线服务容器时，页面内容过多导致的 Session 崩溃的问题。		
大模型广场/任务式建模	[Hot] 全新上线 DeepSeek 全系列模型精调功能，支持两种精调方式，并发布官方最佳实践。 方式一：对 DeepSeek R1 满血版直接进行有监督精调（SFT） 方式二：使用 DeepSeek R1 作为教师模型，蒸馏精调其他较小尺寸的学生模型 支持DeepSeek 全系模型： DeepSeek-R1-Distill-Qwen-1.5B DeepSeek-R1-Distill-Qwen-7B DeepSeek-R1-Distill-Llama-8B DeepSeek-R1-Distill-Qwen-14B DeepSeek-R1-Distill-Qwen-32B DeepSeek-R1-Distill-Llama-70B DeepSeek-R1-671B DeepSeek-V3-671B	2025-02-18	使用 DeepSeek-R1 蒸馏其他模型的全流程实践 精调满血版 DeepSeek-R1 全流程实践
大模型广场/在线服务	[Hot] 新增支持 DeepSeek R1 蒸馏系列模型。参数规模最小低至1.5B，可使用更小算力资源进行部署。新增支持的模型包括： DeepSeek-R1-Distill-Qwen-1.5B DeepSeek-R1-Distill-Qwen-7B	2025-02-02	大模型广场 DeepSeek 部署和体验实践教程

	DeepSeek-R1-Distill-Llama-8B		
	DeepSeek-R1-Distill-Qwen-14B		
	DeepSeek-R1-Distill-Qwen-32B		
	DeepSeek-R1-Distill-Llama-70B		

2025年01月

动态名称	动态描述	发布时间	相关文档
大模型广场	[Hot] 全新上线 DeepSeek 模型，支持一键部署推理服务。 支持的模型包括： DeepSeek-V3 DeepSeek-R1	2025-01-27	DeepSeek 部署和体验实践教程
Notebook/任务式建模	1. Notebook新增Python环境轻量基础内置镜像； 2. Notebook远程SSH连接支持VPC内访问地址； 3. Notebook和任务式建模统一CFS路径配置体验，支持在配置CFS源路径时直接创建新路径； 4. Notebook和任务式建模创建实例时合并CFS和CFS Turbo选项卡统一为CFS； 5. Notebook支持挂载COS存储桶（该功能属于公测阶段，如有测试需求请联系产品经理开启白名单）。	2025-01-23	SSH 网络配置指引

 [最新动态_AI开发平台ModelArts_华为云](#)

2025年03月

序号	功能名称	功能描述	阶段	相关文档
1	在ModelArts Studio查看预置服务的调	MaaS提供调用统计功能，支持查看预	商用	在ModelArts Studio (MaaS) 查看预置

	用数据	置服务中商用服务在指定时间段内的调用数据详情，包括消耗Tokens、输入Tokens和输出Tokens，并以小时为最小时间粒度展示数据趋势，帮助您监控服务使用情况和资源消耗。		服务的调用数据
2	在ModelArts Studio 预置服务中开通商用服务	MaaS预置服务的商用服务为企业用户提供高性能、高可用的推理API服务，支持按Token用量计费的模式。该服务适用于需要商用级稳定性、更高调用频次和专业支持的场景。	商用	在ModelArts Studio（MaaS）预置服务中开通商用服务
3	基于ModelArts Studio DeepSeek API和Cursor快速构建代码编辑器	使用Cursor调用部署在ModelArts Studio上的DeepSeek模型，构建代码编辑器。	商用	基于ModelArts Studio（MaaS）DeepSeek API和Cursor快速构建代码编辑器
4	基于ModelArts Studio DeepSeek API和Cline快速构建AI编程助手	使用Cline调用部署在ModelArts Studio上的DeepSeek模型，构建AI编程助手。	商用	基于ModelArts Studio（MaaS）DeepSeek API和Cline快速构建AI编程助手
5	基于ModelArts Studio DeepSeek API和RAGFlow快速构建AI助理	使用RAGFlow调用部署在ModelArts Studio上的DeepSeek模型，快速构建AI助理。	商用	基于ModelArts Studio（MaaS）DeepSeek API和RAGFlow快速构建AI助理
6	基于ModelArts Studio DeepSeek API和Deep Research快速实现行业洞察	使用Deep Research调用部署在ModelArts Studio上的DeepSeek模型，快速实现行业洞察。	商用	基于ModelArts Studio（MaaS）DeepSeek API和Deep Research快速实现行业洞察

2025年02月 

序号	功能名称	功能描述	阶段	相关文档
1	资源池节点支持开启/关闭删除锁	为了防止节点被误删除或退订，您可以根据业务情况对	商用	管理Lite Cluster节点

		节点开启删除锁。 开启删除锁的节点将无法正常使用删除/退订功能，需要关闭删除锁才可以进行删除/退订。		
2	事件中心页面授权运维	针对ModelArts运维平台告警的故障节点，控制台“资源管理 > 事件中心”页面记录故障节点的计划事件，包括故障节点的基本信息、事件类型、事件状态、事件描述等，并支持授权和重部署操作，授权华为技术支持对故障节点进行运维。	商用	管理Lite Cluster节点
3	在Lite Cluster资源池上使用Ascend FaultDiag工具完成日志诊断	在ModelArts Lite环境下使用Ascend FaultDiag工具进行日志诊断的过程，包括日志采集、日志清洗、故障诊断三个步骤。	商用	在Lite Cluster资源池上使用Ascend FaultDiag工具完成日志诊断
4	基于MaaS DeepSeek API和Cherry Studio快速构建个人AI智能助手	使用Cherry Studio调用部署在ModelArts Studio上的DeepSeek模型，快速构建个人AI助手。	商用	基于MaaS DeepSeek API和Cherry Studio快速构建个人AI智能助手
5	基于MaaS DeepSeek API和Dify快速构建网站智能客服	使用MaaS的免费Token额度的满血版DeepSeek-R1 API接入Dify（开源Agent平台），快速构建AI对话机器人并将其嵌入在网页中。	商用	基于MaaS DeepSeek API和Dify快速构建网站智能客服
6	MaaS支持使用DeepSeek模型实现对话问答	在MaaS控制台领取免费额度并体验DeepSeek-R1模型，快速实现对话问答。	商用	使用ModelArts Studio的DeepSeek-R1模型框架实现对话问答
7	开启/关闭专属资源池节点绑定	当资源池下已创建逻辑子池，支持开启节点绑定，为逻辑子池绑定专属的节点。	商用	查看Standard专属资源池详情

8	Standard资源池节点支持换绑逻辑子池	Standard专属资源池开启节点绑定后，资源池内的节点可换绑指定的逻辑子池。	商用	查看Standard专属资源池详情
---	-----------------------	---	----	-----------------------------------

2025年01月 

序号	功能名称	功能描述	阶段	相关文档
1	MaaS支持多数据模板和权重转化	模型调优页面支持根据不同模型框架选择不同的模板框架上传数据集，支持Huggingface和Megatron两种权重格式。 • Huggingface格式可直接创建为我的模型或者添加为当前调优模型新版本。 • Megatron格式需要将权重转换为Huggingface格式之后，才能创建为新的模型或者创建已有模型的新版本。	商用	使用MaaS调优模型

<https://support.cucloud.cn/document/127/591/1398.html?id=1398&arcid=2829>

 千帆平台更新记录 文心大模型

<https://cloud.baidu.com/doc/WENXINWORKSHOP/s/D1fmc9dxj#2025%E5%B9%B45%E6%9C%88>

<https://cloud.baidu.com/doc/WENXINWORKSHOP/s/D1fmc9dxj#2025%E5%B9%B44%E6%9C%88>

2025年3月 

日期	功能类别	功能描述
3月28日	API相关	更新 模型精调 相关API： · 模型支持情况说明 ：SFT新增支持模型DeepSeek-V3-0324。
3月28日	SDK相关	SDK新增支持调用DeepSeek-V3-241226模型。
3月27日	模型训练	精调任务扩充基础模型选择范围： RFT新增QwQ-32B、新增ERNIE-Code-3-128K、SFT新增DeepSeek-

		V3、Post-pretrain支持ERNIE-4.0-turbo-128K。
3月27日	API相关	更新 模型精调 相关API： · 模型支持情况说明 ：RFT新增支持模型QwQ-32B；DPO新增支持模型ERNIE-Code-3-128K。
3月27日	SDK相关	DeepSeek-V3 版本升级，最新版本为 DeepSeek-V3-250324。新版本在数学推理、代码生成能力以及长上下文理解能力方面有显著提升。
3月21日	SDK相关	更新 批量预测 相关文档： · 获取批量预测任务详情 ：新增响应参数version。 · 获取批量预测任务列表 ：新增响应参数version。
3月20日	模型训练	· SFT新增 DeepSeek-R1-Distill-Qianfan-Llama-70B ：并支持全量和LoRA训练方法。 · RFT新增 Qwen2.5-7B-Instruct ：支持GRPO、PPO的全量更新方法。
3月20日	API相关	更新 批量预测 相关API： · 获取批量预测任务详情 ：新增返回参数version。 · 获取批量预测任务列表 ：新增返回参数version。 更新 模型精调 相关API： · 模型支持情况说明 ：SFT新增支持模型DeepSeek-R1-Distill-Qianfan-Llama-70B；RFT新增支持模型Qwen2.5-7B-Instruct；更新RFT相关模型的超参配置信息。
3月16日	模型广场	全面支持文心大模型4.5 API调用 ，文心大模型X1即将上线！
3月14日	API相关	更新 算力单元服务付费 相关API： · 查询算力单元列表 ：响应参数status新增状态BillingChanging，表示计费变更中。 · 查询算力单元详情 ：响应参数status新增状态BillingChanging，表示计费变更中。
3月14日	SDK相关	更新 算力单元服务付费 相关文档： · 查询算力单元列表 ：响应参数status新增状态BillingChanging，表示计费变更中。 · 查询算力单元详情 ：响应参数status新增状态BillingChanging，表示计费变更中。

3月13日	模型训练	SFT 及 DPO 新增多款基础模型底座：您可在更大的范围内选择合适的模型。
3月13日	模型广场	新增图像理解、重排序、向量表示等 20余项大模型 版本：平台提供预置模型，您可部署专属服务。
3月13日	API相关	更新 模型精调 相关API： · 创建模型精调任务 ：新增请求参数rlMethod。 · 模型支持情况说明 ：SFT新增支持QwQ-32B，DPO新增支持ERNIE-4.0-Turbo-8K，更新Qwen2.5-7B-Instruct等多个模型。
3月10日	SDK相关	更新 数据管理 相关API： · 创建数据集 ：dataFormat的支持类型新增SFT_FIM，表示Prefix+Suffix+Middle数据格式。 · 获取数据集列表 ：dataFormat的支持类型新增SFT_FIM，表示Prefix+Suffix+Middle数据格式。 · 新增数据集版本 ：dataFormat的支持类型新增SFT_FIM，表示Prefix+Suffix+Middle数据格式。 · 获取数据集版本详情 ：dataFormat的支持类型新增SFT_FIM，表示Prefix+Suffix+Middle数据格式。 · 获取数据集版本列表 ：dataFormat的支持类型新增SFT_FIM，表示Prefix+Suffix+Middle数据格式。
3月6日	数据管理	新增 FIM 结构 支持进行SFT训练：提高大模型的内容补全能力，使模型能够在给定上下文中预测中间缺失的内容，而不仅仅是从左到右生成文本。
3月6日	API相关	更新 模型精调 相关API： · 模型支持情况说明 ：SFT新增支持DeepSeek-R1-Distill-Qwen-1.5B、Qwen2.5-7B-Instruct；RFT新增支持DeepSeek-R1-Distill-Qwen-7B；DPO新增支持DeepSeek-R1-Distill-Qwen-14B；图像理解新增支持Qwen2.5-VL-7B-Instruct、Qwen2-VL-7B、Qwen2-VL-2B；更新SFT部分模型的超参配置信息

日期	功能模块	功能描述
2月27日	SDK	SDK目录更新，推理服务API V1相关文档已迁移至 SDK-历史文档 。
2月27日	模型训练	新增 RFT训练方式 ：通过自动化生成的奖励信号驱动模型优化，让模型通过多轮试错和反馈逐步提升推理能力。适用于答案明确、需要逐步推理，以及数据量小数据标注成本高的场景中。
2月27日	官方文档	平台文档 指引页 更新：您可根据本指引页快速获取您想了解的平台操作知识和流程。
2月27日	API相关	更新 模型精调 相关API： · 模型支持情况说明 ：RFT新增支持模型DeepSeek-R1-Distill-Qwen-14B；SFT新增支持模型Qianfan-Sug、DeepSeek-R1-Distill-Qianfan-Llama-8B；DPO新增支持模型Qianfan-Sug；更新SFT部分模型超参配置信息。 更新 模型管理 相关API： · 新建我的模型版本 ：新增请求参数basicModelName和enablePromptAutoConcat。 · 新建我的模型 ：更新modelType支持的模型类型。
2月26日	API相关	更新 模型精调 相关API： · 创建模型精调任务 ：新增请求参数rewardRule，表示奖励规则。 · 模型支持情况说明 ：更新图形理解类型模型部分参数信息。
2月26日	SDK相关	更新 模型精调 相关API： · 创建模型精调任务 ：新增请求参数rewardRule，表示奖励规则。
2月24日	SDK相关	更新 批量预测 相关API： · 创建批量预测任务 ：新增请求参数version，表示推理任务接口版本。
2月21日	模型调优	平台上线模型蒸馏功能及 精调样板 ：利用一个效果较好的大参数规模模型（称为“教师模型”）的知识，来指导一个较小参数规模的模型（称为“学生模型”）的训练，使得学生模型在参数量和计算复杂度较低的情况下，尽可能接近甚至超越教师模型的效果。

2月21日	API相关	更新模型精调相关API： · 模型支持情况说明：ERNIE系列部分模型新增支持LoRA-GA训练；SFT新增支持模型DeepSeek-R1-Distill-Qwen-32B、DeepSeek-R1-Distill-Qwen-7B。
2月19日	SDK相关	新增用户记忆相关SDK文档： · 创建用户记忆id：用于创建用户记忆id。 · 写入用户记忆内容：用于在用户记忆中写入多条记忆内容，即更新一个appId下某userMemoryId的记忆内容。 · 查询用户记忆内容：用于查询用户记忆内容，支持查询单个用户所有的记忆内容或单条记忆内容。 · 查询应用内所有用户记忆id：用于查询应用内所有用户记忆id。 · 修改用户记忆内容：用于修改用户记忆中的单条记忆内容。 · 删除用户记忆id和记忆内容：用于删除用户记忆id和对应的记忆内容。 更新推理服务V2相关SDK文档 · 对话Chat：返回参数新增reasoning_content。
2月18日	最佳实践	官方文档新增ERNIE用户记忆机制实践教程：比较重要的信息会作为Bot的长期记忆作为管理，在实际使用时会按需进行提取或使用。
2月15日	模型训练	SFT新增基础模型DeepSeek-R1：单条数据支持8k tokens。
2月15日	预置服务	新增DeepSeek-R1-Distill-Qianfan-Llama-70B和DeepSeek-R1-Distill-Qianfan-Llama-8B，您可于文档中心查看调用。
2月13日	模型评估	自动评估新增基线评测：当前预置了知识问答、逻辑推理、阅读理解、文本生成四种能力的基线评估数据集，开启基线评测后展示。
2月13日	API相关	更新模型精调相关API： · 创建模型精调任务：SFT支持角色扮演（括号文学）任务。 · 模型支持情况说明：SFT新增支持模型DeepSeek-R1-Distill-Qwen-14B；KTO新增支持模型ERNIE-3.5-8K。

2月13日	SDK相关	更新 模型精调 相关SDK文档： · 创建模型精调任务 ：SFT支持角色扮演（括号文学）任务。
2月12日	API相关	新增 用户记忆 相关API： · 创建用户记忆id ：用于创建用户记忆id。用户记忆id标记着不同用户的独特身份，后续需根据用户记忆id进行对用户记忆进行增删改查。 · 查询用户记忆内容 ：用于查询用户记忆内容，支持查询单个用户所有的记忆内容或单条记忆内容。 · 删除用户记忆id和记忆内容 ：用于删除用户记忆id和对应的记忆内容。 · 查询应用内所有用户记忆id ：用于查询应用内所有用户记忆id，即根据用户提供的应用appId查询对应的用户所有的记忆内容。 · 写入用户记忆内容 ：用于在用户记忆中写入多条记忆内容，即更新一个appId下某userMemoryId的记忆内容。 · 修改用户记忆内容 ：用于修改用户记忆中的单条记忆内容。
2月5日	SDK相关	SDK新增支持调用DeepSeek-V3、DeepSeek-R1模型。
2月3日	预置服务	全面支持 DeepSeek模型 调用，价格超低

2025年1月

日期	功能模块	功能描述
1月23日	模型广场	平台 模型广场 新增语音大模型：声音复刻、语音合成等，您可试用模型体验效果。
1月23日	数据管理	数据回流升级 推理日志挖掘 ：支持海量推理日志的检索分析。
1月23日	模型训练	· DPO 及 SFT 训练支持ERNIE-Character-8K：百度自研的垂直场景大语言模型，适合游戏NPC、客服对话、对话角色扮演等应用场景，人设风格更为鲜明、一致，指令遵循能力更强，推理性能更优。 · RLHF训练支持 ERNIE-Tiny-8K 作为基础模型训练：单条数据支持8192 tokens。

1月23日	API相关	更新模型精调相关API： · 模型支持情况说明：RM新增支持模型ERNIE-Tiny-8K；PPO新增支持模型ERNIE-Tiny-8K；更新相关模型超参配置信息。
1月21日	SDK相关	更新推理服务V2相关SDK文档： · 对话Chat：新增请求参数metadata。 更新模型服务相关SDK文档： · 获取定制服务详情：新增返回参数urlSuffix，表示创建服务时对应的API地址。
1月20日	SDK相关	更新模型管理相关SDK文档： · 获取导入模型平台预置高级配置：新增请求参数basicModelName，表示基础模型版本名称。 · 获取模型详情：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取我的模型列表：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取预置模型详情：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取预置模型列表：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取模型版本详情：新增响应参数resourceType，表示资源类型。
1月16日	API相关	更新模型管理相关API： · 获取导入模型平台预置高级配置：新增请求参数basicModelName，表示基础模型版本名称。 · 获取模型详情：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取我的模型列表：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取预置模型详情：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取预置模型列表：新增响应参数modelName，表示模型拥有的模型版本号列表。 · 获取模型版本详情：新增响应参数resourceType，表示资源类型。

		更新模型服务相关API： · 获取定制服务详情：新增返回参数urlSuffix，表示创建服务时对应的API地址。 更新模型精调相关API： · 模型支持情况说明：图像理解类型，SFT新增支持模型InternVL2.5-8B。
1月13日	SDK相关	更新推理服务V1相关SDK文档： · 对话Chat相关：Python SDK、Go SDK、Java SDK新增支持请求参数metadata。 · 对话模式：Python SDK、Go SDK、Java SDK新增支持请求参数metadata。 · 对话Chat（精调后）：Python SDK、Go SDK、Java SDK新增支持请求参数metadata。 更新推理服务V2相关SDK文档： · 对话Chat V2相关：SDK新增支持请求参数web_search和响应参数search_results。
1月10日	API相关	更新推理服务V2部分内容： · 获取BearToken值方式，新增通过在控制台页面，创建并获取API-KEY，详细说明请参考认证鉴权。
1月9日	模型训练	· 模型精调方式合并：您可同平台创建/对比不同训练方式内容。 · SFT新增ChatGLM4-9B作为基座模型进行训练：智谱 AI 推出的预训练模型 GLM-4系列中的开源版本。
1月9日	模型评估	模型评估新增：支持您从BOS中导入数据进行评估。
1月9日	精调样板	新增文本创作字数控制 V2：以RLHF为基础训练方式进行的精调样板。
1月9日	API相关	更新模型精调相关API： · 模型支持情况说明：SFT新增支持模型ChatGLM4-9B。
1月7日	SDK相关	SDK新增更新以下内容： · 对话Chat：新增支持请求参数enable_user_memory、user_memory_extract_level，分别表示是否开启用户记忆、用户记忆抽取级别。

		新增私有资源池服务付费相关SDK文档： · 购买算力单元：用于用户购买算力单元。 · 查询算力单元列表：用于用户筛选算力单元列表信息。 · 查询算力单元详情：用于用户查询指定算力单元详细信息。 · 算力单元变配：用于用户变更算力单元配置。 · 释放后付费算力单元：用于用户释放算力单元。 · 定时释放后付费算力单元：用于用户设置算力单元后付费定时释放时间。
1月3日	SDK相关	SDK新增支持调用以下服务推理API： · Qianfan-Agent-Speed-32K：Qianfan Agent是百度自研Agent专用版模型，针对企业级大模型应用进行了专门的指令调优，在问答场景、智能体相关场景可以获得同等规模模型下更好的效果。2025年1月2号发布的版本，支持32K上下文长度。 新增模型服务相关SDK文档： · 下线定制服务：用于下线定制服务。 · 扩缩容定制服务：调整服务当前使用算力单元实例的部署副本数或为服务添加一个新的算力单元实例。 新增模型评估相关SDK文档： · 更新模型评估任务：用于更新模型评估任务信息。 · 查看模型评估结果导出任务状态：用于获取模型评估导出任务状态信息。 · 发起模型评估结果导出任务：用于创建模型评估结果导出任务。 · 停止模型评估任务：用于停止模型评估任务。
1月2日	API相关	更新TPM配额管理相关API： · 购买TPM配额：请求参数model新增支持Qianfan-Agent-Speed-32K。 · 查询TPM配额信息详情：请求参数model新增支持Qianfan-Agent-Speed-32K。 · 终止按小时后付费TPM配额：请

		求参数model新增支持Qianfan-Agent-Speed-32K。 更新模型精调相关API： · 模型支持情况说明：DPO新增模型Baichuan2-7B-Chat。
1月2日	SDK相关	更新TPM配额管理相关API： · 购买TPM配额：请求参数model新增支持Qianfan-Agent-Speed-32K。 · 查询TPM配额信息详情：请求参数model新增支持Qianfan-Agent-Speed-32K。 · 终止按小时后付费TPM配额：请求参数model新增支持Qianfan-Agent-Speed-32K。 更新模型服务相关API： · 创建定制服务：新增请求参数protocolVersion、deploymentConfig，分别表示服务版本、部署配置。 · 获取定制服务列表：新增请求参数protocolVersion，表示服务版本；新增响应参数protocolVersion和deploymentConfig，分别表示服务版本和部署配置。 · 获取定制服务详情：新增请求参数protocolVersion，表示服务版本；新增响应参数protocolVersion和deploymentConfig，分别表示服务版本和部署配置。
1月2日	模型精调	DPO训练新增支持Baichuan2-7B-Chat。Baichuan2是百川智能推出的新一代开源大语言模型。 Baichuan2-7B-Chat单条数据支持4096 token，是在大约1.2万亿token上训练的70亿参数模型。

🔥 新功能发布记录2025.4--机器学习平台-火山引擎

🔥 新功能发布记录2024.11--机器学习平台-火山引擎