

路由器误抢不发免费ARP问题分析与解决方案

原理介绍：路由器高可用实现原理


主备高可用导致的互抢场景分析


主备高可用导致的互抢对流量的影响

问题1：备网络节点重启时，可能误抢主网络节点上的路由器

问题2：备网络节点误抢主网络节点路由器后，主网络节点又抢回，不发送免费ARP

原理介绍：路由器高可用实现原理





1. vrouter 部署与优先级规则

创建vrouter时，按网络节点承载的路由器数量排序，数量越少的节点优先级越高。vrouter 默认部署在高优先级节点，仅当更高优先级节点失联时，低优先级节点才启动对应的 vrouter。优先级支持手动调整，可根据网络拓扑需求灵活配置主备节点顺序。

2. 故障检测机制

基础链路检测：网络节点间、网络节点与计算节点（仅当节点上有访问外网的虚机时）通过bfd检测，默认发包周期 740ms-1000ms，最大故障探测时间 3000ms，感知主节点失联。

故障判断逻辑：

若收到对端报文，重置计时器，若3s内一直收不到下一个报文，则认为对端失联。



3. 主备切换流程

BFD测到主网络节点失联，低优先级备网络节点立即激活 vrouter，更新自身与路由器网关的绑定关系，下发对应的网络流表并发送 GARP 协议包。计算节点流表保持 bundle 格式不变，通过 ovs-vswitchd 的 revalidator 线程更新 megaflow，自动将数据包指向新的备网络节点 IP。单台计算节点故障时，不影响网络节点及其他计算节点上的 vrouter 运行。


4. 恢复切换逻辑

当原故障主节点恢复正常后，将 vrouter 切换回原高优先级节点。备网络节点发现主节点BFD up，则释放这个vrouter。

主备高可用导致的互抢场景分析

BFD状态	互抢场景	主备路由器	互抢分析	图解	缓解方案	缓解方式弊端
BFD down→up	• 网络节点重启 • 业务网络从down到up	主路由器	主节点上任意一个BFD up，此时备节点上还没看到主节点up时会和主节点相互抢，等到两个节点都up后，不再争抢		网络down到up可以通过BFD全down到第一个BFD up感知到，所以第一个BFD up时，等待3s，等到所有BFD up	备节点发现主已经up，则释放路由器，但是主节点还会sleep 一会导致中断0-3s
		备路由器	备节点上任意一个BFD up（主还没up），则抢路由器，此时主节点会抢回去，相互抢，等到两个节点都up后，不再争抢			无
BFD up→down	业务网络从up到down	主路由器	主节点上BFD还没全down，此时备节点上看到主节点BFD down，这时候会相互抢，等到两个节点都down后，不再争抢		无法知道我的网络是不是down了，所以无缓解方案	-
		备路由器	备节点上主节点的BFD down的时候，但是其他节点BFD还有up的时候，会和主节点相互抢，等到两个节点都down后，不再争抢			-

主备高可用导致的互抢对流量的影响



备网络节点误抢路由器，如果误抢后发出免费ARP，则影响外部交换机流量发给错误的备网络节点A，主网络节点B通过流量更新交换机ARP表（对业务影响很小），主网络节点B通过抢回路由器发送免费ARP更新交换机ARP表（对业务影响时间是备网络节点发送免费ARP到主网络节点发送免费ARP之间的时间）。

针对误抢后发出免费ARP，外部交换机更新自己的ARP表，导致外部来的流量通过ARP查表找到了错误的网络节点导致丢包，然而虚机发往外部的流量依然通过正确的网络节点发送到外部交换机。外部交换机如果开启了MAC联动ARP功能，交换机发现使用的MAC从主网络节点B上来，会自动更新ARP表，所以只要有虚机发往外部的流量会立刻将外部交换机的ARP表更新对，不会出现问题。

然后对于华为交换机的VBDIF接口而言，交换机收到网络流量后，触发MAC联动ARP功能时，他不会立刻更新ARP表，而是通过发送ARP请求来确认这个MAC在哪个口，如果此时备网络节点A回复了ARP请求（还没有被主网络节点B抢回去），ARP表不会更新，交换机会在5分钟之后再发送一次ARP请求确认，也就是这5分钟从外部来的流量都发送到了错误的网络节点，流量被丢弃。

问题1：备网络节点重启时，可能误抢主网络节点上的路由器

误抢的概念：主网络节点正常的时候，主备网络节点间网络时延是正常的时候（即BFD up的时间有上限），备网络节点不应该抢主网络节点上的路由器，比如备网络节点重启时，不应该误抢，比如备网络节点网络断了，网络恢复后，不应该误抢（这两种场景可以描述为所有bfd从全down到up的过程，且up的时间有上限）。如果网络时延不稳定，或者主网络节点负载高，导致主备网络节点之间BFD包收发不稳定，即主网络节点的BFD up时间不可控，导致的备网络节点抢走路由器，不属于误抢。

网络节点重启时，ovs会先启动，ovs与其他网络节点，计算节点创建的隧道端口也会启动，此时会自动与其他节点建立BFD，如果不干涉，ovs启动后，BFD建立好以后，如果有路由器的主在这个节点，那么备网络节点发现主网络节点BFD up，则会释放自己的路由器，而主网络节点只会在ovn-controller启动以后设置路由器，造成业务中断时间长。

这个问题的方法是节点重启后br-vxlan网络不自动启动，在ovn-controller启动正常以后，再up br-vxlan。br-vxlan up以后，BFD心跳就开始工作，不过BFD从down到up会有一些时间，很可能导致一些BFD up了，但是主路由器所在网络节点的BFD 还没有up，会让ovn-controller误抢这个路由器，所以产品实现里加了[sleep 2s](#)等待所有BFD up（以前没有深入分析BFD从down到up的时间，以为只要收到一个BFD心跳包就可以UP）。但是根据分析 [OVS bfd 的状态变化机制](#)，BFD up的最快时间是2个网络时延比如5+5=10ms，ovs正常情况下，网络时延正常情况下，最慢2s+单程网络时延 up。如果ovs负载高或者网络时延不稳定，up的时间无法判断，这种备节点抢路由器是无法避免的。

根据BFD包发送的实现，每隔T ms ($740\text{ms} \leq T \leq 1000\text{ms}$)发送一个BFD包，收到包以后，BFD状态会发生变化，我们假设网络时延200ms，我们可以每隔1.2s（除了网络时延，还有[BFD处理时延](#)，需要在邮储大规模环境确认后定出时间）检测一次所有BFD的状态（最优的是只检测所有网络节点的BFD状态）最多检测3次，即3.6s，如果2次检测BFD的状态相同，则认为正常的网络节点已全部UP。

非自动化的方式可以更大程度上处理网络时延不稳定，或者主网络节点负载高的特殊场景，这种只能人为判断。比如节点down机或重启时（bfd 全部down的时候），先隔离这个节点，等节点启动以后确认没有任何问题时，则手动启用这个节点。

问题2：备网络节点误抢主网络节点路由器后，主网络节点又抢回，不发送免费ARP

这是一个明确的bug，备节点误抢主节点路由器以后，主节点网络并没有问题，所以主节点并没有释放这个路由器，备节点抢过去以后，会更新sb数据库里的port_binding的chassis为自己，主节点发现以后会立刻更新回去，如果网络分区（即主节点网络是好的，备节点与主节点BFD down，与其他节点BFD up）持续，主备会一直不断抢路由器，当网络分区恢复后，主会抢到路由器，备会释放路由器。由于主节点网络一直没问题，所以没有执行过释放路由器的动作，所以当路由器抢回来以后，不会发送免费ARP。

针对这个问题的详细分析与修复参考：[路由器网关garp报文发包流程梳理](#)